

量子コンピューティングI NISQ編 #4

第8回 量子AI (QML)

情報工学科 佐藤貴彦

#1	#2	#3	#4	#5	#6	#7	#8	#9	#10	#11	#12	#13	#14
Intro.	量子回路	Deutsch	Grover	実機実装	QAOA	誤り緩和	量子AI	誤り訂正	論理演算	符号理論	量子中継	QIアプリ	総括
基礎編 #2-4 (完)				NISQ 編 #5-8				FTQC 編 #9-11			量子インターネット編 #12-13		


三目並べソルバーを作って、古典AIと量子AIの違いを学ぶ

- ① 古典AIを復習する
- ② 量子AIで三目並べを解く
- ③ 古典AIと量子AIの違いを考える

今日のゴール

三目並べソルバを古典・量子・ハイブリッドの3通りで作ри、強さを 定量化する

- 三目並べを打つソルバを、中身の違う3通り(古典NN / 量子QNN / ハイブリッド)で作る
- 同じ土俵で戦わせ、強さを Eloレーティング という1つの数値に変換して横並べする
- ✓ 同じ問題を 古典・量子・ハイブリッド のAIで解くと、強さはどう違うか
- ✓ 小さい盤で動くなら、大きな問題ではどうなるか



● 古典AI復習

量子AIで三目並べ

違いを考える


QMLを見る視点

QML は古典深層学習の各部品を量子版に差し替えたものである

- QML は新しい分野ではなく、
既知の機械学習の部品を量子に置き換えた構成
- この視点なら、各手法は
「何が量子になったか」だけを追えばよい
- 差し替える前に、まず古典AIを思い出そう

B2の機械学習基礎で
一通り学んだでしょうか？

古典AIのキーワード




今日はなぜ量子で三目並べを解くのか


三目並べは古典でも簡単. 量子で解く狙いは (高性能ではなく) 3つのAIを同じ土俵で測ること

- 三目並べは古典で容易に解ける (最善どうしは引き分け)ので、量子優位の主張は狙わない
- Eloレーティング という統一指標で古典・量子・ハイブリッドのAI性能を比較できる

Eloレーティング(後述)は
勝率を元にした相対評価指標
直接比較が難しいAIの性能を
ゲームの実力で評価する試み▶
<https://arxiv.org/abs/2503.21514>
Kamei et al., (2025)



測定器としての三目並べ



既習アルゴリズムで三目並べは・・

Grover

13-18Qubit, 数百ゲート, NISQには重い

QAOA

9-18Qubit, 一手ごとに回路再生成が必要


QML

小さくても、動く (大事)

古典・量子AIを4象限で分類する

QML はデータ×アルゴリズムで整理でき、本講義は古典データ×量子アルゴリズムを扱う

- 2軸で整理する:
データ(古典 / 量子) × アルゴリズム(古典 / 量子)
- 本講義は古典データ×量子アルゴリズムが中心、
量子データ×量子は終盤に少し
- 量子AIに期待されるのは
計算速度・新しいアルゴリズム・資源効率
- まず古典側の足場を固める



NN・最適化・逆伝播

NN は関数、最適化は勾配で動かす操作、逆伝播は勾配を出す手段と考える

- NN = 重みを持つ関数(線形変換と非線形活性化の繰り返し)
- 最適化 = 重みを勾配の方向に動かして損失を下げる (SGD / Adam)
- 逆伝播 = 勾配を効率よく一括計算する手段(連鎖律)
- 役割分担: 定義はNN・動かすのは最適化・方向を出すのは逆伝播

ナイーブな逆伝播は
複製不能+測定で崩壊するため
量子では使うことが 難しい
(勾配計算はできる)

NN

関数(重みを持つ)

最適化

勾配で重みを動かす

逆伝播


勾配を出す手段(連鎖律)

誤差逆伝播法（Backpropagation）と量子の相性

逆伝播は連鎖律に頼るが、量子回路は計算途中を測ることが難しい

- 逆伝播の核心は連鎖律。中間出力を保持し、出力側から微分を掛け合わせる
- 量子回路は中間状態を古典的に取り出せない（情報量が指数関数的に多い）ため、中間値を取って連鎖律を回せない
- 帰結: 量子層の勾配を **逆伝播では** 出せない


勾配の出し方は後半で回収
先に強化学習へ進む



強化学習の骨格を三目並べに当てはめる

エージェントは Q値・Bellman更新・ ϵ -greedy で行動を学ぶ

- Q値 = ある盤面で、ある手を打つことの価値
(価値 = 将来累積報酬の期待値)
- Bellman更新 = 次の盤面の最大 Q で今の Q を直す
- ϵ -greedy = 確率 ϵ で探索、残りで最善手を選ぶ
- Q値を出すのがネットワーク



Sec.I まとめ | 古典AIの部品を思い出した

三目並べソルバーをまず古典で動かし、AIを量子に置き換えて強くする

取り扱ったこと

- QML は古典部品の差し替えという視点
- 古典AI: NN・最適化・逆伝播・強化学習という構成要素を復習
- どうやら「逆伝播が量子で使えなさそう」

Next: Sec.II 量子AIで三目並べを解く

盤面を入れたら一手を返すソルバを

- まずは古典で動かし
- AIを量子に置き換え
- 強さを測る

✓ 古典AI復習

● 量子AIで三目並べ


違いを考える

三目並べソルバを考える

盤面を入れたら次の一手を返すソルバ: 盤面9マス → 9マスのスコア → 一番高いマスに打つ

- Sec.IIで作るもの = 三目並べソルバ
盤面を入れたら9マスに「打つ価値」のスコアを出し、一番高いマスに打つ
- 盤面は9次元の数値: 自分の石=+1 / 相手=-1 / 空=0
先手後手で入れ替わるので、盤面に手番をかけ常に自分の石が+1に見えるようにする
- 中央の「AI」(盤面→9スコア) を、まず古典で作し、次に量子に置き換えて強くしていく
- まず古典だけで動くものを作る


同じネットワークを
先手・後手で兼用したい



古典AIの場合

古典では AI = 古典NN($9 \rightarrow 9$)で各マスのスコアを出す。これがソルバの最小構成

- 一番素朴な AI = 古典の全結合NN。9次元の盤面を入れ、9個のスコアを出す ($9 \rightarrow \dots \rightarrow 9$)
- スコア = 各マスのQ値 (そこに打つと将来どれだけ勝ちに近づくか)、準備の強化学習の枠で学習
- まずこれを動かす。動いたら AI を量子に置き換える
- 実際に動かしてみよう



実装 | 古典ソルバーを動かす

未学習だと弱い → 学習させると強くなる。まず動く土台を作る

- ・ 盤面を入れて9スコア → 一手 が返るところまでをまず動かす
- ・ 未学習の AI はでたらめに打つ (弱い)、学習させると勝ちにつながる手を選ぶ (強くなる)

```
python
env      = TicTacToe()
ai       = ClassicalAI()

# 盤面→スコア→一手
s        = ai(encode(board))
move     = argmax(s[legal])

# 学習させる
train    (ai, games=800)
```

未学習

+1	-1	
	+1	
-1		

スコアはばらばら

vs ランダム 勝率

0.48

(ほぼ互角?)

学習 (800戦)

+1	-1	
	+1	
-1		

勝ちにつながる手へ

vs ランダム 勝率


0.86

(完璧でなくて良いが) ソルバが一度動いたので、これを土台にする。ここから AI を量子に置き換えて強くしたい

量子AIの構成要素

量子AIの処理フローは古典かけ離れたものではない

- 量子でもやることは変わらない： 盤面情報を入れて、最も評価の高い次の手を出す
- ただし量子回路で作るには3部品が要る：
①載せる(盤面を量子状態に) ②処理する(量子回路で計算) ③読み出す(測定して数値に戻す)
- [ここだけ一般論] 古典NNではあまり問題にならないが、量子だと データ入力=Encoding は厄介な問題
(量子に載せやすく、古典で取り扱いにくいデータが量子AIの勝ち筋とも考えられている)




同じ仕事 (盤面→指し手) を、量子は3部品で組む

データを載せる (Encoding)

量子AIはまず盤面を量子状態に載せる機能が必要

- AI に「データを載せる」
古典NNは9次元の盤面をそのまま入力した
- 量子には古典データをそのまま入れられず、
まず量子状態に載せる(Encoding)必要がある
- 方式は色々ある: Basis / Amplitude / Angle / IQP...
三目並べは9次元を回転角に載せる(Angle系)が基本
- Feature Map = 非線形変換をかける載せ方 (ZZ等)
線形分離できない特徴空間を作りうる

AI の3部品のうち



古典 9次元の盤面をそのまま入力

量子 まず量子状態に載せる機能 (Encoding) が要る

載せ方の選択肢

Basis

ビット列そのまま

Amplitude

確率振幅に

Angle

回転角に (本講義)

IQP

浅い回路で複雑分布

実装 | Encoding回路は入力に依存・非学習

盤面を量子状態に載せるための方法は複数ある

- 本講義では、古典AIのカーネル法を元にした FeatureMap を採用する
- FeatureMapにもさまざまな方式があり、もつれの有無と深さが変わる
- 三目並べは”もつれを使わない Angle系”を基本に、性能改善に必要ななら ZZ などでもつれを足す


ZFeatureMap, Angle H + 位相 / もつれなし

ZZFeatureMap 対へ位相 / もつれあり

TPE, Angle Rx のみ / もつれなし

HEE Rx + CX鎖 / 軽いもつれ

例: ZZFeatureMap (n=3) の回路



データを処理する (ansatz)



古典NNの重みに当たるのパラメータが回転角 θ 。回路の形(ansatz)を固定し θ を学習する。

- AI の「処理」部
古典NNは重みを学習したが、量子は回路の形(ゲートの並び=ansatz)を固定し、回転ゲートの角度 θ だけを学習する
- θ の最適化は古典・回路実行は量子の分担 (NISQ向け)

勾配/Parameter shift の話 (後述)

- 注意: PQC はParametric Quantum Circuitの略で、耐量子暗号 (Post Quantum Crypto.) とは無関係

AI の3部品のうち



実装 | データを処理するパラメータ θ を学習・最適化する

処理回路(ansatz)を選び、reps と qubit 数で θ の数が決まる

- AI の「処理」部の実装。ansatz(回転ゲート+もつれ層)を選ぶ
- 同じ qubit 数でも EfficientSU2 は回転が2種類で θ が多い。reps を増やすと表現は上がるが、学習は重くなる

RealAmplitudes

Ry + CX もつれ層


EfficientSU2

Ry, Rz + もつれ層

θ の数 (reps=2)

	n=3	n=8
RealAmplitudes	9	24
EfficientSU2	18	48

例: RealAmplitudes (n=3, $\theta \times 9$) の回路



データを読み出す (Sampler / Estimator)

測定の仕方確率分布(2^n)か期待値(n)に分かれ、盤面評価へ繋ぐ後段が変わる

- 古典NNは盤面評価 (9マスのスコア) を直接出したが、量子は測定で取り出すしかなく扱いが2通りある

1. Sampler = 測定の確率分布(2^n 次元)



- ビット列の (擬) 確率を得る
 - ✓ 実機運用だと多数のショットが必要
 - ✓ シミュレーションだと厳密にわかる

2. Estimator = 各qubitのZの期待値(n 次元)

- 期待値 $\langle \psi | H | \psi \rangle$ を得る
 - ✓ 誤差付きの数値が得られる

QAOAではEstimatorで最適化を進め、そのあとSamplerで解候補を得るなど複合的な使い方をする

AI の3部品のうち




後段 (盤面評価) の次元が変わる

Barren Plateau (不毛な大地)問題

Qubit数が増えると勾配が指数的に平坦化する、量子固有の勾配消失問題

- 量子AI回路のqubit数を大きくすると、勾配が指数的に平坦化し学習が止まる (Barren Plateau問題)
- 古典の勾配消失と語感はあるが、原因も深刻さも異なる 量子AI特有の問題と考えて良い
- 大きくするほど深刻 = スケーラビリティへの障壁




qubit が増加すると勾配の分散が指数的に減少していく

古典・量子ハイブリッドAI

AI全体を量子にせず、古典NNで量子NNを挟む方式


- 全量子AIだと大規模化し、さまざまな問題が発生する
- 古典線形NNと量子層を組み合わせることで性能向上を図る
- 三目並べソルバの場合：
 - 盤面の9ビット情報を 古典LinearNNで圧縮 (9→4)
 - 量子層(4 qubit)で処理を行う
 - 古典LinearNNで読み出し(4→9) → 次の手を得る
- 量子NNのサイズを絞り込むことで回路を浅く保てる (NISQ向け)



実装 | ハイブリッドAIを組む

Sampler版(後段入力 2^n)とEstimator版(後段入力 n)の2系統で組む

- 読み出しに合わせ後段Linearの入力次元を決める: Sampler版=Linear($16 \rightarrow 9$)、Estimator版=Linear($4 \rightarrow 9$)
- 同じ圧縮Linear・同じansatzでも、読み出し形式で後段の形が変わる



後段入力のデータサイズが異なる以外は同一の構成

構成によるパラメータ数の違い

読み出し形式で後段パラメータ数が変わるが、それだけが強さを決めるのではない

- Sampler版は後段入力 $2^n=16$ でパラメータが多い (計201)
- Estimator版は後段入力 $n=4$ でパラメータが少ない (計93)
- Estimator版(少パラメータ)も古典を上回る → パラメータ数だけが決定要因ではない
- 量子層を学習させたいが勾配が要る
逆伝播の問題に戻る

後段Linearとパラメータ数 (N=4)

	後段入力	後段	合計
Sampler版	16	153	201
Estimator版	4	45	93


次の問い: 量子層を学習させたいが勾配が要る → 逆伝播の問題へ

量子層の学習：Parameter shift

量子層の勾配は θ を $\pm\pi/2$ ずらした測定値の差で得られる

- 「量子層の勾配は逆伝播では出せない」ので、代わりにParameter shiftという手法を導入する
- θ を $+\pi/2$ と $-\pi/2$ にずらして測定し、その出力差から勾配を得る
- Rx, Ry, Rzの回転ゲートに対しては厳密な勾配が得られる

できるだけ少ない計算回数で、
できるだけ高精度な勾配を得るため
さまざまな研究が行われている




有限差分よりノイズに堅牢とされる

TorchConnector

量子層をPyTorch層として挟み、古典層とまとめてAdamで学習できる

- TorchConnectorは、量子層をPyTorchの1層としてモデルに挟みこむ
 - 量子層の局所勾配はParameter shiftが供給し、外側の古典層のautograd連鎖に接続される
- ✓ パイプライン全体が微分可能＝まとめてAdamで学習可
- ✓ 「伝播が使えない」は量子層内部の話で、学習全体は地続きにして運用できる



1本のautograd計算グラフ → まとめてAdamで学習


AIが完成したので、強化学習の枠に載せてみよう

AIを差し替える

枰 (盤面→AI→スコア→次の一手) は同じまま、AIだけ古典/量子/ハイブリッドに差し替える

- 最初に作った枰はそのまま。中央のAIだけを差し替える
- 古典NN / 量子QNN / ハイブリッド、どれを差ししても枰は不変
- 同じ土俵に乗るので、勝率で 強さ = AIの性能 として比較できる・・・はず (NN単体の同等性は保証されない)

Eloレーティング比較の成立条件



実装 | 自己対戦で強くする

自己対戦で学習 ▶ 学習率を上げすぎると壊れる ▶ 戻すと直す

- ・ 3つのAI(古典/量子/ハイブリッド)を同じ枠で自己対戦学習： 先手後手を入れ替えて公平に
- ・ 演習の主軸 = 動かす → 壊す → 直す

動かす → 壊す → 直す (学習率を変える)

動かす

健全な学習率で学習 → 古典は安定して強くなる (Elo 1707)

壊す

学習率を上げすぎる ($lr=0.3$) → 学習が発散 (Elo 507, 差1200)

直す

学習率を戻す → Elo が回復。最も効くレバー

試してみよ

手番正規化の有無 / ϵ の大小 / 経験再生・ターゲットネット / qubit数


演習の最後に、壊したAI・直したAIと自分で対戦して強さの差を体感できる (ノート EX10)

Eloレーティング

強さを1つの数値にする（基準R1500・K=32 で勝敗と期待勝率のズレから更新する）

- Elo = 強さを1つの数値で表す指標、基準Rは1500
 - 期待勝率 $W = 1 / (10^{((R_{\text{相手}} - R_{\text{自分}})/400)} + 1)$
 - 更新 $R' = R + K (\text{勝数} - \text{試合数} \cdot W)$ 、 $K = 32$
- （映画ソーシャル・ネットワーク(2010)で出てきましたね）
 - 強い相手に勝つと大きく上がる、逆も然り
 - 差70 ≈ 勝率60%、差20-30はゆらぎ
- 今回はランダム戦略と対戦し100ゲームごとに更新する

注: 絶対値そのものは実装固有スケールなので重要ではない
EloレーティングはAI 間の相対順位を読む指標として用いる




レーティング差が大きいほど期待勝率は0/1に飽和

AIを変えてソルバを動かす

同じ枠でAIだけ変えた3つを動かすと、打ち筋が目に見えて変わる

- 最初に作ったソルバーを、AIだけ古典/量子/ハイブリッドに差し替えた3つで、同じ盤面に打たせる
- 同じ枠・同じ学習でも、AIによって選ぶ手が変わる。
「どれが強いかな」は打ち筋だけでは決められない



同じ盤面でも、AI が違えば選ぶ手が違う (Elo はまだ出さない)


実験結果 | 3つの量子ソルバーをEloで比較する

Eloで測ると、古典量子ハイブリッドは古典を超え、量子単体は今回の規模では性能不足

- ハイブリッド > 古典 > QCNN > QNNになるはず
 - ✓ qubitを増やすほどハイブリッドのEloが上がる
 - ✓ QNNは1500前後で停滞＝ランダムと同等
 - ✓ QCNNはQNNよりも性能が出る

- パラメータ数、Qubit数に依存するため、手法の優劣を決定づける結果ではないことに注意
- 解析的な議論と似た結果になることは興味深い

縦軸は相対 (数値自体に意味はない) / QCNN・QNNとも量子



Sec.II まとめ | ソルバを作って評価した

次はその結果の意味と、QML全体への広がりを見る

取り扱ったこと

- 三目並べソルバをまず古典で動かした
- AIの構成要素を量子で組んだ
- Eloで古典・量子・ハイブリッドを比較した

Next: 古典AIと量子AIの違いを考える

- 結果の意味 を考える
- 同じ発想の手法・全体の見立て を俯瞰する

✓ 古典AI復習

›

✓ 量子AIで三目並べ


›

● 違いを考える


考察 | 実機での挙動・伸びしろはあるか？

(ノイズフリーでも終盤の守りが甘い点には目をつぶって)


- ノイズのある現実の環境でもソルバ動くのか？
 - ✓ 学習済みソルバーをノイズ付きシミュレータで動かしてみよう
 - ✓ 我々の論文には実機との対戦棋譜も載ってます
 - <https://arxiv.org/abs/2503.21514>
- NISQレベルの回路で戦術的な要素を組み込めるか？
 - ✓ 例：石を揃える戦術は見せるが、終盤の守り(相手のリーチを止める)が甘い



自分(O)が攻める



相手(X)のリーチ



守れず負け


現在の制約下でも対話的に遊べるが、もっと強くする方法はあるか？

議論 | 量子AIにスケラビリティ・優位性はあるのか？

今回設計した三目並べソルバでは、少ないパラメータ・小さい規模で動くものができた

- 規模を大きくしたら量子優位は出るのか？
- ✓ Qubitを増やすとBarren Plateau問題が発生する
- ✓ 回路を深くすると局所最適の壁やノイズの影響が大きくなる



- 規模だけでなく、優位の出る条件・構造も重要
- 現在の最前線でもあり、QMLの可能性は未知数



議論 | 量子インターネットへの応用可能性

ノイズ通信路を挟んでも性能低下は限定的で、広域量子アプリでQMLが活躍するかもしれない

- 遠隔量子サーバを用いた量子アプリはどのようなものがあるだろうか？
 - ✓ 医療データ+量子連合学習、量子センサ+QMLなど応用は広そう（第13回で解説予定）




ここからはQMLの他のアプローチを俯瞰する。まずは、原型となったPQCの代表例・VQEを見てみよう

関連研究 | VQE


PQCと古典最適化で、行列の最小固有値を求める原型的なアルゴリズム

- 目的: ある行列の最小固有値を求める
(物理では基底エネルギー)
- 試行状態の期待値は最小固有値以上 (変分原理) →
PQCの状態でこれを最小化する θ を探す
- 浅い回路で動くが、測定コスト大・ansatz依存

- 量子化学計算と相性がよく、
NISQ黎明期に活躍したアルゴリズム
- 多くの後継アルゴリズムを生み出した



Global Phase: $(-0.5)*\theta[3] - 0.5*\theta[4] - 0.5*\theta[5] - 0.5*\theta[9] - 0.5*\theta[10] - 0.5*\theta[11]$




「PQC + 古典最適化」の原型。以降の QSVM・QGAN・QCNN すべてがこの被せ方を踏襲する

古典AIの復習 | SVM とカーネル法

マージン最大の境界を引き、カーネルトリックで非線形分離を内積だけで行う

- SVM = 最も近い点までの距離(マージン)が最大の境界を選ぶ。決めるのがサポートベクトル
- まっすぐ分けられないデータも、高次元へ写す(ϕ)と平面で分離できる
- ϕ 自体は要らず、2点の内積 $K(x, x') = \langle \phi(x), \phi(x') \rangle$ だけでよい = カーネルトリック




カーネルトリックの典型例

内積 K だけで非線形分離が可能 (カーネルトリック)。この K を量子で計算するのが次の QSVM

関連研究 | QSVM

カーネル(特徴空間の内積)だけを量子で計算し、最適化は古典SVMを再利用する


- カーネルKの計算だけ量子回路で行う
- 量子側の特徴写像 = Feature Map(前半で見たZZ等)が、古典 ϕ の量子版
- 2019年に5QubitマシンでQSVMが実装・実証された
 - Havlíček et al., "Supervised learning with quantum-enhanced feature spaces", Nature 567, 209–212 (2019)



量子 part
カーネル K を推定

古典 part
SVM で最適化

特徴写像 = Feature Map (ZZ等) の回路:




量子は K の計算だけ担当し最適化は古典に任せる。古典のSVM資産をそのまま活かせる

GAN, 敵対的生成ネットワーク

GeneratorとDiscriminatorをminimaxで競わせ、本物そっくりの分布を生成する

- 分類器は「入力→ラベル」の識別モデル、生成モデルは「分布を学び新データを作る」
- GAN = Generator(偽物作る)とDiscriminator(本物/偽物を見分ける)を競わせる
- minimaxを交互に回すとGが本物そっくりの分布を作る。分布がつぶれる失敗(モード崩壊)もある



本物の分布に近づいていく



(最近は生成AI一辺倒ですが)
実在しない動物の動画の高速生成などは画期的だった

競わせて分布を生成する骨格。この G/D を量子回路にするのが次の QGAN

関連研究 | QGAN

G/Dを量子回路で実装し、競わせる骨格は古典GANと同じ

- G/Dをminimaxで競わせる骨格はそのまま
- GとD(片方/両方)を量子回路で実装する
- 量子状態が表せる分布の広さに期待。ただし古典データを量子状態へ埋め込む段(Encoding)のロスで質が落ちる



骨格は古典GANと同じ / 中身が量子回路

2018年に提案、2019年に初実装された
<https://www.science.org/doi/10.1126/sciadv.aav2761>


広い分布表現に期待。一方 Encoding ロスが質を左右する → 量子化の難所はデータの読み込み

復習 | QCNN

畳み込みを局所ユニタリ、プーリングをトレースアウトで実現し、パラメータが少ない

- CNNの骨格 = 局所性とパラメータ共有
 - ✓ 畳み込み層 = 局所ユニタリ
 - ✓ プーリング層 = 一部qubitを測定しトレースアウトして次層入力を減らす
- パラメータがqubit数に対数的にしか増えず、Barren Plateauの壁を避けやすい

QCNN 回路 (畳み込み = 2qubitユニタリ / プーリング = 制御回転で縮約。測定は読み出し時):



Qubit数が減っていくので構造的にBarren Plateau を避けやすい

これからの量子AIはどこに向かうのか？

古典データならハイブリッド、量子データはQMLで処理する方向に向かっていくかもしれない

- 古典データを使うなら、Encodingが大きな壁となる
 - ✓ 大規模な古典データを量子コンピュータに載せることは難しい
 - ✓ 古典NNでデータを量子NNに埋め込むハイブリッドは現実的に思える
 - ✓ 量子層が古典モデルに対して優位性を発揮するかはまだわかっていない
- 量子データ (量子センサ・量子通信経由) をQMLで直接処理する・・・？
 - ✓ 例：量子センサでデータ生成 → 量子サーバで低ショット処理の量子エッジ
 - ✓ ノイズの影響や秘匿性の増強など、多くの視点から検討する必要がある
- FTQC時代には状況がどう変わる？
 - ✓ 大規模・代数的アルゴリズムが実装可能になることで高度な処理が可能になる
 - ✓ AIにいつ、どれくらい貢献するようになるかはこれからの研究課題

Quantum Machine Learning: from NISQ to Fault Tolerance	
Yunfei Wang ¹ and Junyu Liu ^{2,3,4,5,6,7}	
¹ Martin A. Fisher School of Physics, Brandeis University, Waltham MA 02453, USA	
² Qibla Co., Chicago, IL 60615, USA	
³ Chicago Quantum Exchange, Chicago, IL 60637, USA	
⁴ Department of Computer Science, The University of Chicago, Chicago, IL 60637, USA	
⁵ Pritzker School of Molecular Engineering, The University of Chicago, Chicago, IL 60637, USA	
⁶ Kadanoff Center for Theoretical Physics, The University of Chicago, Chicago, IL 60637, USA	
⁷ SeQuire, Chicago, IL 60615, USA	
(Dated: January 23, 2024)	
Quantum machine learning, which involves running machine learning algorithms on quantum devices, has garnered significant attention in both academic and business circles. In this paper, we offer a comprehensive and unbiased review of the various concepts that have emerged in the field of quantum machine learning. This includes techniques used in Noisy Intermediate-Scale Quantum (NISQ) technologies and approaches for algorithms compatible with fault-tolerant quantum computing hardware. Our review covers fundamental concepts, algorithms, and the statistical learning theory pertinent to quantum machine learning.	
CONTENTS	
I. Introduction	1
II. Noisy intermediate-scale quantum (NISQ) era	4
A. Variational quantum algorithm (VQA)	4
B. Quantum neural tangent kernel	9
C. Quantum landscapes and barren plateaus	11
III. Fault tolerant quantum computation (FTQC) algorithms	13
A. Quantum phase estimation and quantum principle component analysis	13
B. Classical algorithm framework for dequantizing QML models	15
C. Harrow-Hassidim-Lloyd algorithm	15
D. Quantum random access memory	18
IV. Statistical learning theory	19
A. Shadow tomography	20
B. Classical shadow formalism and random measurements	22
C. Quantum machine learning for quantum data and quantum simulators	24
V. Conclusion and discussion	25
Acknowledgement	25
References	25
I. INTRODUCTION	
Quantum machine learning represents a highly promising realm in contemporary physics and computer science research, with far-reaching implications spanning quantum chemistry [1], artificial intelligence [2], and even high-energy physics [3]. Nevertheless, it remains in its nascent stages of development. This is evident from the absence of a precise definition for quantum machine learning. Some describe it as the convergence of quantum computing and machine learning, wherein machine learning algorithms are executed on quantum devices. In simpler terms, it can be thought of as the quantum counterpart to classical machine learning.	
In recent times, artificial intelligence, exemplified by technologies like CHAT GPT, has become an integral part of everyday life. It's entirely plausible that, in the future, we will harness artificial intelligence in an even wider array of applications, including medical diagnostics, education, and aiding scientific research. Much of artificial intelligence's success hinges on	

<https://arxiv.org/pdf/2401.11351v1>

まとめ

量子AIの構造を学ぶため、三目並べソルバを作った

- 古典AIの部品(NN・最適化・勾配)を量子に差し替え、三目並べソルバを古典・量子・ハイブリッドで作ってEloで定量化した
- 既習の Grover/QAOA では厳しい三目並べが QML で動いた
- 量子AI は古典AIからかけ離れたものではなかった
- 古典AIと量子AIの違い
= 量子優位は無条件でなく、設計・問題次第で不明なことも多い
- FTQC時代の手法はアプローチが変わってくる
 - ✓ 深い量子サブルーチンを用いたアルゴリズムも運用できる
 - ✓ 線形代数処理の高速化で活躍するかもしれない
- 次回からはFTQCの思想と設計を見ていきましょう

