

量子AI (QML) 副読本

[量子AI \(QML\) 副読本 — 三目並べソルバーで学ぶ量子機械学習](#)

[超要約 \(150字以内\)](#)

[読むのにかかる目安](#)

[この副読本の構成](#)

[前提知識マップ](#)

[テーマ対応表 \(スライド・ノートとの対応\)](#)

[§ 0 前提：量子ゲートの最小復習](#)

[§ 1 全体像：QMLとは「部品の差し替え」](#)

[§ 2 古典側の足場：NN・最適化・逆伝播・強化学習](#)

[§ 3 なぜ逆伝播が量子で使えないか](#)

[§ 4 データを載せる：Encoding / Feature Map](#)

[§ 5 データを処理する：ansatz と PQC](#)

[§ 6 データを読み出す：Sampler / Estimator](#)

[§ 7 量子層の勾配：Parameter shift](#)

[§ 8 ハイブリッド構成](#)

[§ 9 強化学習の数理：Q学習とBellman更新](#)

[§ 10 強さの定量化：Elo](#)

[§ 11 動かす→壊す→直す：学習率と発散](#)

[§ 12 量子固有の壁：Barren Plateau](#)

[§ 13 関連手法の俯瞰：VQE・QSVM・QGAN・QCNN](#)

[§ 14 考察：量子優位はどこにあるか](#)

[実装パート：論文の4エンジンを組み立てる](#)

[§ E0 全体像：エンジンという単位](#)

[§ E1 古典エンジン：CNN / CCNN](#)

[§ E2 量子単体エンジン：QNN](#)

[§ E3 量子畳み込みエンジン：QCNN](#)

[§ E4 ハイブリッドエンジン：HNN](#)

[§ E5 実験結果：Eloで7エンジンを比べる](#)

[§ E6 QCNNは三目並べ以外で何に使えるか](#)

[全体のまとめ](#)

[読者プロフィール更新提案](#)

量子AI (QML) 副読本 — 三目並ベソルバーで学ぶ量子機械学習

- ・対象資料: 講義「量子コンピューティングI NISQ編 #4 / 第8回 量子AI (QML)」スライド全42枚 + 演習ノートブック (EX1~EX10)
- ・元論文: Kamei et al. (2025), arXiv:2503.21514
- ・想定読者: 情報工学科 学部3年。量子回路は読め、ゲートは一通り既習 (復習込み)。量子は専門外。

著作権注記: 本副読本は個人学習用に作成された資料である。論文中の図は学習補助目的で引用しており (フェアユース)、著作権は原著者に帰属する。研究室外への配布・Web 公開・SNS への投稿は行わないこと。

超要約 (150字以内)

QMLは古典機械学習の各部品 (NN・最適化・勾配・カーネル・GAN・CNN) を量子回路に差し替えたものである。本講義は三目並ベソルバーを古典/量子/ハイブリッドで作り、Eloで強さを定量化する。量子単体は小規模では古典に届かないが、要所だけ量子にするハイブリッドは古典に並ぶ/上回る。

読むのにかかる目安

- ・概念パート (§ 0~§ 14) 通読で約 90~120 分。数理を追うなら +60 分。
- ・実装パート (§ E0~§ E6) 併読で約 +60 分。
- ・重さ: ★★★★★ (情報工B3・量子非専門に対する主観評価。ゲート復習込みで橋渡しを厚くしてある)

この副読本の構成

本副読本は2部構成である。

- ・概念パート (§ 0~§ 14) : 教科書本体。QMLの原理を、ゲート復習から考察まで概念テーマ単位で解説する。通読で「QMLとは何か」が分かるように書いた。
- ・実装パート (§ E0~§ E6) : 応用編。論文 Kamei et al. (2025) が定義する4つのエンジン (古典・QNN・QCNN・ハイブリッド) を、論文ソースの回路図とノートブックの実コードで解説する。各所で概念パートへ逆参照する。

実装パートは概念パートの原理を前提とし、重複する原理説明は概念パート側に集約してある。「まず概念を通読 → 実装で具体を確認」という読み方を想定している。

前提知識マップ

概念	状態	補足
量子回路の読み方（ゲート・測定の図）	◎	既知。読める前提
1量子ビットゲート（X, H, Rx/Ry/Rz）	○	§ 0で復習。Rが回転角を持つ点を確認
2量子ビットゲート（CX）ともつれ	○	§ 0で復習
測定と状態の崩壊	△	§ 3・§ 6で「中間状態が取れない」理由として解説
期待値 $\langle \psi$	H	$\psi \rangle$
ニューラルネット・勾配降下・逆伝播	○	B2の機械学習基礎で既習想定。§ 2で要点のみ復習
強化学習（Q学習・Bellman）	△	§ 9で導出含め補う
線形代数（固有値・内積・ユニタリ）	○	情報工で既習想定。必要箇所ですぐ軽く触れる
パウリ演算子の代数	△	§ 7のParameter shiftで必要。その場で補う
ランダム行列・ユニタリデザイン	×	§ 12で概念のみ。証明は原典に委ねる

凡例: ◎既知 / ○多分既知 / △副読本で補う / × 別途学習推奨

テーマ対応表（スライド・ノートとの対応）

テーマ	主な対応スライド	対応ノートEX
§ 0 前提：量子ゲートの最小復習	（独自）	EX1の前提
§ 1 全体像：QMLとは「部品の差し替え」	3, 5, 13, 25	—
§ 2 古典側の足場	6, 7, 8	EX2, EX3
§ 3 なぜ逆伝播が量子で使えないか	6, 7	（概念）
§ 4 データを載せる：Encoding	14, 15	EX1
§ 5 データを処理する：ansatz と PQC	16, 17	EX1
§ 6 データを読み出す：Sampler / Estimator	18, 21, 22	EX1, EX7
§ 7 量子層の勾配：Parameter shift	23, 24	EX7
§ 8 ハイブリッド構成	20, 21, 22	EX7, EX8
§ 9 強化学習の数理	8	EX3
§ 10 強さの定量化：Elo	27	EX4

テーマ	主な対応スライド	対応ノートEX
§ 11 動かす→壊す→直す	26	EX5, EX6, EX9
§ 12 量子固有の壁：Barren Plateau	19, 33	EX9
§ 13 関連手法の俯瞰	35～40	—
§ 14 考察	31～34, 41, 42	EX10
§ E0～E6 実装パート（4エンジン+応用）	25, 29	EX1～EX10 + 論文

§ 0 前提：量子ゲートの最小復習

対応: 独自（EX1・EX6で出てくるゲートの予習）

要点

QMLで決定的に重要なゲートは、回転ゲート R_x, R_y, R_z （連続パラメータ θ を持つ）と、もつれを作る CX （CNOT）である。学習とは、この θ を動かすことに他ならない。

背景知識

1量子ビットの状態はブロッホ球上の点で表せる。回転ゲートはこの球面上の回転で、

$$R_x(\theta) = e^{-i\theta X/2}, \quad R_y(\theta) = e^{-i\theta Y/2}, \quad R_z(\theta) = e^{-i\theta Z/2}$$

と書ける。 X, Y, Z はパウリ行列である。指数の肩に $-i\theta P/2$ （ P はパウリ演算子）という形が乗っている点が、後で **Parameter shift**（§ 7）が厳密に効く理由に直結する。

R_y を行列で書くと、

$$R_y(\theta) = \begin{pmatrix} \cos(\theta/2) & -\sin(\theta/2) \\ \sin(\theta/2) & \cos(\theta/2) \end{pmatrix}$$

θ を連続的に動かせる = 「つまみ」になる、というのがNNの重みとの対応である。

CX （制御NOT）は2量子ビットゲートで、制御ビットが $|1\rangle$ のときだけ標的ビットを反転する。これが**もつれ（entanglement）**を作る基本部品で、ansatz（§ 5）やFeature Map（§ 4）でビット間に相関を入れるのに使う。

行間

なぜ回転ゲートばかり使うのか。NISQ（ノイズあり中規模量子）時代の制約として「浅い回路しか信頼できない」があり、かつ「学習で動かせる連続パラメータが欲しい」。 R_y ひとつで1パラメータを供給でき、 CX で固定のもつれを足せば、**少ないゲートで表現力のある可変回路**が組める。これがansatzの設計思想である。

用語

原語	訳語/定着訳	短い定義
Pauli operator	パウリ演算子	X, Y, Z 。固有値が ± 1 、2乗すると単位行列
Rotation gate	回転ゲート	$R_x(\theta)$ 等。連続パラメータ θ を持つ1量子ビットゲート
Entanglement	もつれ	複数ビットが分離不能に相関した状態。 CX で生成

§ 1 全体像：QMLとは「部品の差し替え」

対応: スライド3, 5, 13, 25

訳（スライドの主張の再構成）

QMLは新しい分野ではなく、既知の機械学習の部品を量子に置き換えた構成である。
NN→QNN、畳み込みNN→QCNN、カーネル法→QSVM、生成対抗ネットワーク→QGAN、勾配計算→Parameter shift、というように、各古典部品に量子版が対応する。したがって各手法は「何が量子になったか」だけを追えばよい。

要点

本講義の枠組みは「**枠は共通、中身のAIだけ差し替える**」（スライド25）。盤面9次元 → AI → 9スコア → argmax → 一手、という枠を固定し、中央のAIを古典NN / 量子QNN / ハイブリッドに差し替えて、同じ土俵（Elo）で比べる。

背景知識

QMLの整理軸は2つ（スライド5）：**データ（古典/量子）** × **アルゴリズム（古典/量子）** の4象限。本講義が扱うのは「古典データ × 量子アルゴリズム」。三目並べの盤面は古典データ（9個の数値）であり、それを量子回路で処理する。

この4象限は § 14 の考察、および § E6 (QCNN の応用) で「QML の勝ち筋は古典データより量子データにあるのでは」という議論につながる。古典データを量子に載せる段 (Encoding, § 4) にコストがかかるため、最初から量子状態であるデータ (量子センサ・量子通信由来) の方が量子処理と相性がよい、という見立てである。

行間

「部品の差し替え」が成立するのは、古典 ML の多くが「パラメータ付き関数を勾配で最適化する」という共通骨格を持つからである。量子回路もパラメータ θ を持つ関数とみなせる (PQC, § 5) ので、同じ最適化ループに乗る。「微分可能なパラメータ付き関数」という抽象レベルで見ると、古典 NN と量子 PQC は同じ箱であり、これが差し替えを可能にしている。

読解ヒント

スライド 13・25・28 は同じ「盤面 → AI → スコア → 一手」の図を繰り返す。これは冗長ではなく、「**枠は不変、AI だけ可変**」を視覚的に刷り込む意図がある。図が出たら「今どの AI が中央に入っているか」だけを確認すればよい。

§ 2 古典側の足場：NN・最適化・逆伝播・強化学習

対応: スライド 6, 7, 8 / ノート EX2 (encode)、EX3 (Classical AI)

訳 (スライドの主張)

NN・最適化・逆伝播の役割分担は、**定義するのが NN、動かすのが最適化、方向を出すのが逆伝播**である (スライド 6)。NN は重みを持つ関数、最適化は重みを勾配方向に動かす操作 (SGD / Adam)、逆伝播は勾配を効率よく一括計算する手段 (連鎖律) である。

要点

この三者の分業を押さえると、QML で何が置き換わるかが見える。NN (関数) は量子回路に置き換わり、最適化 (Adam) はそのまま古典に残り、逆伝播 (連鎖律) は量子では使えず Parameter shift (§ 7) に置き換わる。

背景知識

ノートの Classical AI (EX3) は、スライド 6 の「NN = 重みを持つ関数」の最小実装である。

```
nn.Sequential(
  nn.Linear(9, hidden), # 線形変換: 9次元 → 隠れ層
  nn.ReLU(),           # 非線形活性化
  nn.Linear(hidden, 9), # 線形変換: 隠れ層 → 9次元スコア
)
```

この W_1, W_2 （重み）が、量子版では回転角 θ に置き換わる（§5）。

`encode`（EX2）は盤面を9次元ベクトルに直す前処理で、手番 `pplayer` を掛けて「自分の石を常に+1」に揃える（`turn_normalize`）：

$$v = \text{board} \times \text{player}$$

これにより同じネットワークを先手・後手で兼用できる（スライド10）。

行間

手番正規化を切ると（EX9で実験できる）、AIは「先手の+1」と「後手の+1」を別物として学ばねばならず、**実質2倍のパターンを覚える羽目になる**。データ効率が落ち、小さいネットでは学習が安定しにくい。「状態表現の対称性を入力段で潰すと学習が楽になる」という、古典・量子を問わず効く原則の一例である。

用語

原語	訳語/定着訳	短い定義
Fully-connected NN	全結合ニューラルネット	各層が前層の全要素と結合した最も基本的なNN
Activation	活性化関数	ReLU等の非線形変換。これがないと層を重ねても線形のまま
Turn normalization	手番正規化	盤面に手番を掛け「自分=+1」に揃える前処理

§3 なぜ逆伝播が量子で使えないか

対応: スライド6, 7（§7のParameter shift導入の動機）

訳（スライドの主張）

逆伝播の核心は連鎖律である。中間出力を保持し、出力側から微分を掛け合わせて入力側へ伝える。ところが量子回路は中間状態を古典的に取り出せない（情報量が指数的に多い）ため、中間値を取って連鎖律を回せない。帰結として量子層の勾配を逆伝播では出せない（スライド7）。

要点

これは「量子だと勾配が計算できない」のではない。「逆伝播という特定の手段が使えない」だけである。勾配自体は別の方法（Parameter shift, § 7）で出せる。

背景知識（厚め）

合成関数 $L = f_3(f_2(f_1(x)))$ の微分は連鎖律で

$$\frac{dL}{dx} = \frac{df_3}{df_2} \cdot \frac{df_2}{df_1} \cdot \frac{df_1}{dx}$$

各因子は、順伝播で計算した中間値を代入して評価する必要がある。だから逆伝播は「順伝播で中間値を全部メモし、逆向きに掛け合わせる」二段構えになる。

量子回路でこれをやろうとすると壁にぶつかる。 n 量子ビットの中間状態は 2^n 個の複素振幅を持つ：

- ・測定で崩壊する：中間状態を覗こうと測定すると、状態が固有状態に射影されて壊れる。連鎖律に必要な「壊さず保持した中間値」が得られない。
- ・古典的に取り出せない：仮に壊れなくても、 2^n 個の振幅を書き出すこと自体が指数的コスト。

この2点で、「中間値を保持して連鎖律を回す」という逆伝播の前提が量子層内部では成立しない。

行間

著者が暗黙に置くのは「量子層をブラックボックスとして扱う」割り切りである。内部で連鎖律を回すのは諦め、外から「入力 $\theta \rightarrow$ 出力（期待値や確率）」の関数とみなす。その関数の勾配を内部構造を覗かずに得る方法がParameter shift（§ 7）。「逆伝播が使えない」は量子層内部の話で、学習システム全体は地続きにできる（§ 7・§ 8）。

読解ヒント

スライド7の対比表の「**x**」が指すのは連鎖律であって勾配そのものではない、と読み替えられればこのスライドは卒業してよい。

§ 4 データを載せる：Encoding / Feature Map

対応: スライド14, 15 / ノートEX1 量子AIの3部品（①載せる ②処理する ③読み出す）の第1部品。具体的な回路図は § E2 を参照。

訳（スライドの主張）

古典NNは9次元の盤面をそのまま入力した。量子は古典数値をそのまま入れられず、まず量子状態に載せる段（Encoding）が要る。載せ方には Basis / Amplitude / Angle / IQP があり、三目並べは9次元を回転角に載せるAngle系が基本である。Feature Mapは非線形変換をかける載せ方（ZZ等）である（スライド14）。

要点

Encodingは量子AIの「入力インターフェース」であり、**学習しない固定の回路**である（入力データに依存するが、つまみ θ は持たない）。

背景知識（厚め）

代表的なEncodingを、何を犠牲にして何を得るかで整理する。

- **Basis encoding**: ビット列をそのまま計算基底に載せる（ $011 \rightarrow |011\rangle$ ）。直感的だが連続値が載せにくい。
- **Amplitude encoding**: 2^n 個の数値を n 量子ビットの確率振幅に載せる。情報密度が指数的に高いが、状態準備の回路が深くなる。
- **Angle encoding（本講義の基本）**: 各数値を回転ゲートの角度に載せる。回路が浅くNISQ向き。
- **IQP / ZZFeatureMap**: Angle系にビット間相互作用（ZZ 項）を加える。 $z_i z_j$ の積の位相により、古典では効率的に計算しにくい特徴空間を作る。

Angle encodingを数式化すると、入力 $x = (x_1, \dots, x_n)$ に対し

$$|\phi(x)\rangle = \left(\bigotimes_{i=1}^n R_y(x_i) \right) |0\rangle^{\otimes n}$$

ZZFeatureMapはこれにアダマール層と、ビット対への $\exp(i x_i x_j Z_i Z_j)$ 的な位相を加える。 $x_i x_j$ という積が入ることで入力に非線形な特徴写像になる点が本質である。

行間

スライドが強調する一文 — 「量子に載せやすく古典で取り扱いにくいデータが量子AIの勝ち筋とも考えられている」 — は講義全体で最も含意の深い箇所の一つである。

古典データを量子に載せる（Encoding）コストが量子処理の利得を食い潰すと、量子優位は消える。だから「最初から量子状態であるデータ」（量子センサ等）を直接処理できればEncodingのロスを回避できる。これが § 14・§ E6への伏線である。**Encodingは単なる前処理ではなく、QMLが古典に勝てるかの分かれ目**である。

ただし「古典で扱いにくいデータを量子で」という主張は未解決部分が多く、スライドが「考えられている」と推量形で書くのは妥当な慎重さである。

用語

原語	訳語/定着訳	短い定義
Encoding	エンコーディング	古典データを量子状態に載せる操作
Feature Map	特徴写像	データを特徴空間に写す回路。古典の ϕ の量子版
Angle encoding	角度エンコーディング	数値を回転ゲートの角度に載せる方式。NISQ向き
ZZFeatureMap	（原語）	ビット対に ZZ 位相を加え非線形特徴を作る Feature Map

読解ヒント

EX1で `z_feature_map(3)` と `zz_feature_map(3)` を描いて比べる。**ZFeatureMapはもつれゲート（CX）がなく、ZZFeatureMapにはある**ことを回路図で確認するのが狙い。実際の回路図は § E2 に論文ソースのものを掲載した。

§ 5 データを処理する：ansatz と PQC

対応: スライド16, 17 / ノートEX1 量子AIの3部品の第2部品。具体的な回路図と論文の組み合わせ表は § E2 を参照。

訳（スライドの主張）

古典NNは構造を決めて重みを学習した。量子は回路の形（ansatz）を固定し、回転ゲートの角度 θ だけを学習する（スライド16）。ansatzは **RealAmplitudes**（Ry + CXもつれ層）や **EfficientSU2**（Ry, Rz + もつれ層）があり、**reps**（繰り返し回数）とqubit数で θ の数が決まる（スライド17）。

要点

PQC = Parametrized Quantum Circuit (パラメータ付き量子回路)。これがQMLの心臓部で、古典NNの全結合層に対応する。「形は固定・ θ だけ動く」が古典の「構造は不変・重みが動く」と対応する。

スライド16の注意書き: PQCは Post Quantum Cryptography (耐量子暗号) とは無関係。情報工の文脈だと耐量子暗号を先に知っていることが多いので混同しないこと。

背景知識 (厚め)

RealAmplitudes の構造は、 n 量子ビット、 $\text{reps} = L$ 層のとき

$$U(\theta) = \left[\prod_{l=1}^L \left(\bigotimes_i R_y(\theta_{l,i}) \right) \cdot \left(\prod \text{CX} \right) \right] \cdot \left(\bigotimes_i R_y(\theta_{0,i}) \right)$$

回転層 (各ビットに R_y) ともつれ層 (CX鎖) を交互に重ねる。パラメータ数は R_y の総数で決まり、`RealAmplitudes(n, reps=L)` なら $n(L+1)$ 個。

EX1の出力で確認できる:

	RealAmplitudes	EfficientSU2
$n = 3, \text{reps} = 2$	9	18
$n = 8, \text{reps} = 2$	24	48

EfficientSU2が倍なのは回転が R_y, R_z の2種だから (各ビットに回転ゲート2つ)。

行間

「回路の形は固定し角度だけ学習する」のは、NISQの制約が厳しいからである。ゲートを増やすほどノイズが乗り、深い回路は信頼できない。「浅く固定した回路で連続パラメータ θ だけ動かして表現力を稼ぐ」設計に追い込まれている。ansatzの選択は「表現力」と「学習しやすさ・ノイズ耐性」のトレードオフを切る作業である。

repsを増やすと表現できる関数のクラスは広がるが、パラメータが増えて学習が重くなり、Barren Plateau (§ 12) やノイズの影響を受けやすくなる (スライド17)。

用語

原語	訳語/定着訳	短い定義
ansatz	アンザッツ (試行関数)	ゲートの並びを固定したパラメータ付き回路の「型」。元はドイツ語

原語	訳語/定着訳	短い定義
PQC	Parametrized Quantum Circuit	パラメータ θ を持つ量子回路。QML の学習対象
reps	繰り返し回数	ansatzの層を何回重ねるか。表現力と重さのトレードオフ
RealAmplitudes	(原語)	Ry + CXもつれ層からなる標準的 ansatz

読解ヒント

$n = 8$ でも θ は数十個オーダーで、古典NN（隠れ層64なら数百～千）よりむしろ少ない。「量子だからパラメータが多い」のではなく、むしろ少ないパラメータで何ができるかという見方をするとQMLの設計思想が見えてくる。

§ 6 データを読み出す：Sampler / Estimator

対応: スライド18, 21, 22 / ノートEX1・EX7

訳（スライドの主張）

古典NNは9スコアを直接出したが、量子は測定で取り出すしかなく、扱いが2通りある（スライド18）。**Sampler** は測定の確率分布（ 2^n 次元）を返す。**Estimator** は各qubitの Z の期待値（ n 次元）を返す。

要点

測定は「量子状態を古典数値に戻す出口」である。SamplerかEstimatorかで出力次元が変わり（ 2^n vs n ）、後段の古典Linearの入力サイズが変わる（§ 8・§ E4）。

背景知識（厚め）

期待値とは何か。量子状態 $|\psi\rangle$ に対し、観測量（エルミート演算子） H の期待値は

$$\langle H \rangle = \langle \psi | H | \psi \rangle$$

で「状態 $|\psi\rangle$ で H を測定したとき得られる値の平均」である。Estimatorが使う観測量は各qubitの Z で、

$$Z_i = I \otimes \cdots \otimes \underbrace{Z}_i \otimes \cdots \otimes I$$

の期待値 $\langle Z_i \rangle$ を n 個並べて n 次元出力にする。 Z の固有値は ± 1 なので $\langle Z_i \rangle \in [-1, 1]$ 。ノート EX7の

```
obs = [SparsePauliOp("I"*(N-1-i) + "Z" + "I"*i) for i in range(N)]
```

がこの $Z_0, \dots, Z_{N-1}$ を作る。

Samplerは何が違うか。測定結果 (n ビットの 0/1 列) の出現確率を返す。 n ビットなら 2^n 通りなので出力は 2^n 次元。

一言で: **Sampler**は生の確率分布 (情報は多いが次元が爆発)、**Estimator**はそれを Z_i で要約した期待値 (次元は n だが情報は圧縮)。

行間

最適化のループでは**スカラーの損失を微分したい**ので次元の小さいEstimatorが向き、最終的に「どのビット列が答えか」を知りたいときは分布そのものが要るのでSampler (スライド18脚注のQAOAの例)。

三目並べでは量子層出力を後段Linearで9スコアに変換する: - Estimator版: $n = 4 \rightarrow$ Linear($4 \rightarrow 9$) - Sampler版: $2^4 = 16 \rightarrow$ Linear($16 \rightarrow 9$)

Sampler版は後段が大きくパラメータが増える (§ E4・§ E5で計201 vs 93)。**スライド22の「Estimator版 (少パラメータ) も古典を上回る $\rightarrow$ パラメータ数だけが決定要因ではない**」は、量子処理そのものが寄与している可能性を示唆する (§ E5で実データ確認)。

用語

原語	訳語/定着訳	短い定義
Sampler	サンプラー	測定結果の確率分布 (2^n 次元) を返す読み出し
Estimator	エスティメータ	観測量の期待値 (n 次元) を返す読み出し
Expectation value	期待値	$\langle \psi H \psi \rangle$ 。測定値の平均
Observable	観測量	測定する物理量に対応するエルミート演算子。ここでは Z_i

読解ヒント

EX7の `build_quantum_layer` で `mode` を切り替えると `out_dim` が `N` と `2**N` で変わる。この一行が後段Linearの入力次元を決める。

§ 7 量子層の勾配：Parameter shift

対応: スライド23, 24 / ノートEX7 本副読本で最も厚く書く箇所。なぜ $\pm\pi/2$ のずらしで「厳密な」勾配が出るのかを導出する。

訳（スライドの主張）

「量子層の勾配は逆伝播では出せない」ので Parameter shift を導入する（スライド23）。 θ を $+\pi/2$ と $-\pi/2$ にずらして測定し、その出力差から勾配を得る。 R_x, R_y, R_z に対しては厳密な勾配が得られる。有限差分よりノイズに堅牢とされる。

要点

Parameter shiftは「勾配を、わずかにずらした2点の関数値の差として厳密に書ける」回転ゲート特有の性質である。古典の数値微分（有限差分）は近似だが、Parameter shiftは（ノイズがなければ）厳密。

背景知識（厚め・導出）

微分したいのは量子層の出力、ある観測量 H の期待値

$$f(\theta) = \langle \psi(\theta) | H | \psi(\theta) \rangle, \quad | \psi(\theta) \rangle = U(\theta) | \psi_0 \rangle$$

鍵: 回転ゲートは $U(\theta) = e^{-i\theta P/2}$ で P はパウリ ($P^2 = I$)。 $P^2 = I$ から指数が有限項で閉じる:

$$e^{-i\theta P/2} = \cos(\theta/2) I - i \sin(\theta/2) P$$

これを代入して整理すると、 $f(\theta)$ は $\cos \theta$ と $\sin \theta$ の1次結合になる:

$$f(\theta) = A \cos \theta + B \sin \theta + C$$

A, B, C は θ に依らない定数。これがParameter shiftが厳密に効く構造的理由である。微分すると

$$f'(\theta) = -A \sin \theta + B \cos \theta$$

θ を $\pm\pi/2$ ずらすと

$$f(\theta + \frac{\pi}{2}) = -A \sin \theta + B \cos \theta + C, \quad f(\theta - \frac{\pi}{2}) = A \sin \theta - B \cos \theta + C$$

差を取ると C が消え、

$$f(\theta + \frac{\pi}{2}) - f(\theta - \frac{\pi}{2}) = 2(-A \sin \theta + B \cos \theta) = 2f'(\theta)$$

したがって

$$f'(\theta) = \frac{1}{2} [f(\theta + \frac{\pi}{2}) - f(\theta - \frac{\pi}{2})]$$

これがParameter shift rule である。極限 $h \rightarrow 0$ を取らず、 $\pi/2$ という有限のずらしで導関数が厳密に出る。

行間

なぜ有限差分より堅牢か。 有限差分 $\frac{f(\theta+h)-f(\theta-h)}{2h}$ は近似誤差を減らすため h を小さくしたいが、小さくすると分母が小さく測定ノイズが**増幅される**。Parameter shiftはずらし幅 $\pi/2$ で固定かつ厳密なので、その綱渡りが要らない。

もう一つの行間: この導出は「ゲートが $e^{-i\theta P/2}$ (パウリ生成子)」に決定的に依存する。任意のゲートでは成り立たない。スライドが「 R_x, R_y, R_z に対しては」と限定するのは、厳密性が成り立つ範囲を正しく述べているからである。

Parameter shift と古典学習の接続 (スライド24)

Parameter shiftは量子層**内部**の勾配を供給する。これを古典の自動微分に接続するのが **TorchConnector** (ノートEX7)。パイプライン全体が「古典Linear → 量子層 → 古典Linear」のとき、古典層は通常のautograd、量子層だけParameter shiftが勾配を供給し、**全体が1本の微分可能な計算グラフ**になりAdamで最適化できる。

スライド24「『伝播が使えない』は量子層内部の話で、学習全体は地続き」は、§3で予告した回収である。

用語

原語	訳語/定着訳	短い定義
Parameter shift rule	パラメータシフト則	θ を $\pm\pi/2$ ずらした期待値の差で勾配を厳密に得る規則
Generator	生成子	$U = e^{-i\theta P/2}$ の P 。回転ゲートではパウリ演算子
autograd	自動微分	計算グラフを辿り勾配を自動計算するPyTorchの機能
TorchConnector	(原語)	量子層をPyTorchの1層として接続する糊

読解ヒント

手を動かすなら、 $U(\theta) = R_y(\theta)$ 、 $H = Z$ 、 $|0\rangle$ で $f(\theta) = \langle 0 | R_y^\dagger(\theta) Z R_y(\theta) | 0 \rangle = \cos \theta$ を確かめるとよい ($A=1, B=0, C=0$ で $f'(\theta) = -\sin \theta$ がシフト則で出る)。

関連して読むとよい論文

Parameter shift rule の原典は Mitarai et al. (2018) “Quantum Circuit Learning” (Phys. Rev. A 98, 032309、arXiv:1803.00745) と Schuld et al. (2019) “Evaluating analytic gradients on quantum hardware” (Phys. Rev. A 99, 032331、arXiv:1811.11184)。一般化シフト則は後者を参照。

§8 ハイブリッド構成

対応: スライド20, 21, 22 / ノートEX7・EX8 論文のエンジン定義・回路図・ノートの実コードは §E4 を参照。

訳（スライドの主張）

全量子AIだと大規模化し問題が発生する。古典Linearで挟み要所だけ量子層にするハイブリッドにする（スライド20）。盤面9を古典Linearで圧縮（9→4）、量子層（4 qubit）で処理、古典Linearで読み出し（4→9）。

要点

ハイブリッドは「**サンドイッチ**」構造である。パンが古典Linear、具が量子層。

盤面9 → 古典Linear(9→4) → 量子層(4 qubit) → 古典Linear(→9) → スコア9

背景知識

ノートEX7の HybridAI の forward に技術的に重要な行がある:

```
x = torch.tanh(self.pre(x)) * np.pi # 量子の入力角度に収める
```

圧縮後の値を $\tanh$ で $[-1, 1]$ に押し込み π を掛けて $[-\pi, \pi]$ に収める。量子層のFeature Mapが角度を受け取る（§4 Angle encoding）ので、入力を角度の定義域に合わせる処理。そのまま入れると 2π を超えて巻き戻り（位相の周期性）が起き学習が不安定になるのを防ぐ。

行間

なぜ「丸ごと量子」を避けるのか。量子層を大きくすると:

1. Barren Plateau（§12）で勾配が消え学習が止まる
2. NISQ実機ではノイズが蓄積し深い回路の出力が信用できない

3. シミュレーションでも 2^n 状態の計算が指数的に重い

ハイブリッドは量子層を小さく保ち（4 qubit程度）これらを回避しつつ、古典層で次元のつじつまを合わせる現実的な妥協である。

もう一つの行間: このサンドイッチが学習可能なのは § 7のParameter shift + TorchConnectorのおかげである。§ 7と § 8は技術的に一体で、Parameter shiftなしにハイブリッドの学習は成立しない。

読解ヒント

EX8で `estimator` と `sampler` の総パラメータ数（93 vs 201、§ E5に詳細）を確認する。スライド29の「Estimator版（少パラメータ）も古典を上回る」と合わせると、「パラメータ数だけが強さを決めるのではない」が具体的な数字で裏付けられる。

§ 9 強化学習の数理：Q学習とBellman更新

対応: スライド8 / ノートEX3・自己対戦ループ（train_selfplay）

訳（スライドの主張）

エージェントはQ値・Bellman更新・ ϵ -greedyで行動を学ぶ（スライド8）。Q値 = ある盤面である手を打つことの価値（将来累積報酬の期待値）。Bellman更新 = 次の盤面の最大Qで今のQを直す。 ϵ -greedy = 確率 ϵ で探索、残りで最善手。

要点

このソルバーが「学習」する中身はQ学習という強化学習の手法である。AIの出力9スコアは各マスのQ値で、自己対戦の記録からこのQ値を正解に近づける。

背景知識（厚め・導出）

Q値: 状態 s （盤面）で行動 a （どのマスに打つか）を取ったときの「将来得られる報酬の総和の期待値」を $Q(s, a)$ と書く。報酬は「勝ったら+1、それ以外0」。

Bellman方程式: 最適なQ値は自己無矛盾な再帰式を満たす:

$$Q(s, a) = r + \gamma \max_a Q(s', a')$$

「いまの手の価値」 = 「即時報酬 r 」 + 「割引率 $\gamma \times$ 次状態で最善を尽くした価値」。 $\gamma \in [0, 1]$ は将来をどれだけ重視するかの割引率。

学習則: 目標値 $\text{target} = r + \gamma \max_{a'} Q(s', a')$ に現在の $Q(s, a)$ を寄せる。これが「次の盤面の最大Qで今のQを直す」の意味。

ノート実装との対応（厚め）

`train_selfplay` (EX3) には三目並べ特有の符号反転がある:

```
if done:
    target_a = r                # 終局: 報酬そのもの
else:
    nq = net(encode(nb, -p, turn_normalize))    # 次は相手番
    target_a = r - gamma * max(nq[i] for i in nlegal) # ← マイナス符号に注目
```

標準のBellmanは $r + \gamma \max Q$ だが、ここは $r - \gamma \max Q$ 。なぜマイナスか。

次の手番は**相手**である。`encode(nb, -p)` で手番を反転して相手視点の盤面を作り、「相手にとっての最大Q値」を得る。相手が最善を尽くす（自分のQを最大化する）と、それは**自分にとっては不利**。だから相手の最大Qを**符号反転**して自分の目標値に組み込む。

これは **minimax型 / self-play** の更新で、「相手の最善 = 自分の最悪」という2人零和ゲームの性質を、1つのネットワークと符号反転で実装している。

ϵ -greedy (act): 学習中、常に最善手だと同じ展開ばかりで未試行の手のQ値が更新されない。確率 ϵ でランダムに打ち（探索）、残りで最善手（活用）。**探索と活用のバランス**が学習の質を左右する。EX9で ϵ を変えて観察できる。

行間

Q学習の枠（状態→Q値→行動）は、Q値を出す関数が何であれ成立する。だから関数を古典NN/量子QNN/ハイブリッドに差し替えても、外側の自己対戦ループ・Bellman更新・Elo評価はそのまま使える。**強化学習の枠が「枠は共通、AIだけ差し替え」（§1）を可能にしている土台**である。

用語

原語	訳語/定着訳	短い定義
Q-value	Q値	状態 s で行動 a を取る価値（将来累積報酬の期待値）
Bellman equation	ベルマン方程式	$Q(s, a) = r + \gamma \max_{a'} Q(s', a')$
discount factor	割引率 γ	将来報酬の重み。0で目先重視、1で長期重視
ϵ -greedy	イプシロングリーディ	確率 ϵ で探索、残りで活用
self-play	自己対戦	エージェントが自分自身と対戦して学習する方式

読解ヒント

EX3の `target_a = r - gamma * max(...)` のマイナス符号は初見で必ず引っかかる。「標準は+なのになぜ-?」→「次は相手番だから」で納得できれば2人ゲームの強化学習の勘所を掴んだことになる。

§ 10 強さの定量化：Elo

対応: スライド27 / ノートEX4

訳（スライドの主張）

Eloは強さを1つの数値で表す指標で基準は1500（スライド27）。期待勝率 $W = 1/(10^{(R_{\text{相手}} - R_{\text{自分}})/400} + 1)$ 、更新 $R' = R + K(\text{勝数} - \text{試合数} \cdot W)$ 、 $K = 32$ 。差70 $\approx$ 勝率60%、差20 $\sim$ 30はゆらぎ。

要点

Eloは「期待と結果のズレでレーティングを動かす」。期待より勝てば上がり、負ければ下がる。絶対値は実装固有スケールなので、AI間の相対順位を読む指標として使う。

背景知識（厚め・式の意味）

期待勝率:

$$W = \frac{1}{10^{(R_{\text{相手}} - R_{\text{自分}})/400} + 1}$$

- ・互角なら指数部 0、 $W = 0.5$ 。
- ・自分が400点高いと指数部 -1、 $W \approx 0.91$ （400点差で勝率約91%）。
- ・分母の 400 は点差と勝率のスケール定数（チェス由来）。

「差70 $\approx$ 勝率60%」を確認: $W = 1/(10^{-0.175} + 1) \approx 0.60$ 。

更新式:

$$R' = R + K(S - N \cdot W)$$

S は実得点（勝ち1・分け0.5）、 $N \cdot W$ は期待得点。実得点が期待を上回れば上がる。 $K = 32$ は更新の大きさ（学習率に相当）。

ノートEX4の `elo_vs_random` がこの式そのものである。

行間

直接比較が難しいAI同士を、**ゲームの実力という共通軸**に投影できるのがElo比較の発想（元論文の核心アイデア）。古典NNと量子QNNは内部構造もパラメータ数も違うが、どちらも三目並べを打てるので勝率を通じて1次元の数値に落とせる。

重要な留保（スライド25・29脚注）：Eloで順位がついても、それは「この枠・この規模・このパラメータ数での順位」である。**Eloは手法の優劣の証明ではなく、同一条件下の相対評価**。この慎重さは§14につながる。

用語

原語	訳語/定着訳	短い定義
Elo rating	Eloレーティング	期待と結果のズレで更新する相対的強さの指標。基準1500
expected score	期待勝率 W	レーティング差から計算する勝率の予測値
K-factor	K値	1回の更新の大きさ。本講義は $K = 32$

読解ヒント

スライド27脚注「映画ソーシャル・ネットワーク(2010)」は、Eloが元来「2者の対戦結果から相対実力を推定する」汎用枠組みで、チェスに限らないという補足。

§ 11 動かす→壊す→直す：学習率と発散

対応: スライド26 / ノートEX5（動かす）、EX6（壊す）、EX9（試してみよ）

訳（スライドの主張）

演習の主軸は「**動かす** → **壊す** → **直す**」（スライド26）。健全な学習率で古典は安定して強くなる（Elo 1707）。学習率を上げすぎる（ $lr=0.3$ ）と発散（Elo 507）。戻すと回復。学習率が最も効くレバー。

要点

学習がうまくいくかはハイパーパラメータに左右され、中でも**学習率 lr が最も効く**。 lr は「重みを1回にどれだけ大きく動かすか」。大きすぎると修正が過剰で学習が発散する。

背景知識（厚め）

勾配降下の更新則は

$$\theta \leftarrow \theta - lr \cdot \nabla_{\theta} L$$

lr は1歩の歩幅。大きすぎると谷底を飛び越え、振動が増幅して発散する。

1次元の2次関数 $L(\theta) = \frac{1}{2}\theta^2$ で見ると、更新は $\theta \leftarrow (1 - lr)\theta$:

- $0 < lr < 1$: 0に収束。
- $1 < lr < 2$: 振動しつつ収束。
- $lr > 2$: $|1 - lr| > 1$ で**発散**。

実際のNNの損失はもっと複雑だが「歩幅が大きすぎると飛び越えて発散」という本質は同じ。
EX6の `lr=0.3` はこのソルバーには大きすぎる歩幅である。

行間

なぜ「壊す」を体験させるのか。「学習率を適切に」と言葉で言われても感覚は身につかない。
壊れたAI（Elo 507、ランダム以下）を見て、`lr`を変えて直る（回復）のを確認すると「ハイパーパラメータが結果を支配する」実感が残る。EX10で壊したAIと対戦できるのも、**数値（差1200）を対戦の手応えとして体で確認する**設計である。

EX9の「試してみよ」は学習率以外のレバー（手番正規化・ ε ・ γ ・読み出し方・qubit数）を**1つずつ**変えて効果を見る演習。「一度に複数変えない」という実験の基本作法も込みで学ばせている。

読解ヒント

EX6の「直す」はコメントアウトされている:

```
# fixed = train_selfplay(ClassicalAI(), games=800, lr=1e-3, ...)
```

自分で外して実行しEloが回復するのを確認するのが演習。**コメントを外す＝自分で「直す」という仕掛けである。**

§ 12 量子固有の壁：Barren Plateau

対応: スライド19, 33 / ノートEX9 主張と分散議論まで厚く、証明の代数骨格は原典に委ねる（ハルシネーション回避の方針）。

訳（スライドの主張）

量子のAIをqubitで大きくすると勾配が指数的に平坦化し学習が止まる（Barren Plateau、スライド19）。古典の勾配消失と語感はあるが原因も深刻さも異なる量子規模に固有の壁。回路を深くすると局所最適やノイズの影響も大きくなる（スライド33）。

要点

Barren Plateau（不毛な大地）は、**qubit数 n が増えると勾配の分散が $\sim 1/2^n$ で指数的に減衰する現象**。勾配がほぼゼロの「平坦な高原」に学習が囚われる。

背景知識（厚め・主張と分散議論）

主張を正確に: 十分表現力の高いランダムPQC $U(\theta)$ に対し、損失 $L(\theta) = \langle \psi(\theta) | H | \psi(\theta) \rangle$ の勾配について

$$\mathbb{E}[\partial_k L] = 0, \quad \text{Var}[\partial_k L] \sim \frac{1}{2^n}$$

が成り立つ（McClean et al. 2018）。期待値0で分散が 2^n に反比例して消える。 n が大きいとランダム初期化で勾配がほぼ確実にゼロ近傍になり、更新がほぼ動かず学習が始まらない。

直感: 表現力の高いPQCはヒルベルト空間（ 2^n 次元）に状態をほぼ一様にバラまく。広大な空間に散らばると、特定方向への損失の感度が平均的に $1/2^n$ に薄まる。**空間が指数的に広いことが勾配を指数的に薄める。**

証明の骨格（ここから先は原典に委ねる）

完全な証明は次の道筋をたどる:

1. PQCがユニタリ群上で**2-デザイン**（ランダムユニタリの低次モーメントを再現する分布）をなすと仮定。
2. 勾配の期待値・分散を、Haarランダムなユニタリに対する積分（Weingarten計算）で評価。
3. 積分を実行すると分散が $1/2^n$ オーダーで減衰することが導かれる。

この計算はランダム行列論の補題に依存する。ここで再構成すると誤りを混入させるリスクが利益を上回るため、**主張（分散 $\sim 1/2^n$ ）と直感まで**を本副読本の到達点とし、証明の代金は原典に当たることを推奨する。

出典: McClean, Boixo, Smelyanskiy, Babbush, Neven (2018) “Barren plateaus in quantum neural network training landscapes”, Nature Communications 9, 4812 (arXiv:1803.11173)。

行間（古典の勾配消失との違い）

	古典の勾配消失	Barren Plateau
原因	深い層で勾配が連鎖律の積で縮む	広いヒルベルト空間で勾配の分散が指数的に薄まる
効くパラメータ	層の深さ	qubit数 n （と表現力）
対策	ReLU・残差接続・正規化など確立	確立した万能策はない。構造の工夫（QCNN等）で緩和

決定的な違いは、古典の勾配消失には実用的対策が揃うが、Barren Plateauは根が深いこと。スライド33が「Qubitを増やすとBarren Plateau」をスケーラビリティの障壁に挙げるのはこのため。量子AIを大きくして強くする素朴な戦略がこの壁にぶつかる。緩和策の一つが § 13・§ E6の QCNNである。

用語

原語	訳語/定着訳	短い定義
Barren Plateau	不毛な大地	qubit数増で勾配分散が指数的に消える量子固有の学習困難
unitary 2-design	ユニタリ2-デザイン	ランダムユニタリの2次までのモーメントを再現する分布
Weingarten calculus	（原語）	ユニタリ群上のHaar積分を計算する手法

読解ヒント

EX9で $N=6$ などqubit数を増やすと学習が進みにくくなる（Eloが上がらない）のを小規模に体験できる。「大きくすれば強くなる」が量子では成り立たないことを手元で確認する演習である。

§ 13 関連手法の俯瞰：VQE・QSVM・QGAN・QCNN

対応: スライド35～40

要点

スライド35の核心: 「PQC + 古典最適化」がすべての原型。VQEがこの被せ方の原点で、QSVM・QGAN・QCNNはその変奏である。§ 1の「部品の差し替え」が具体的な手法群として現れる。

VQE（変分量子固有値ソルバー、スライド35）

目的: ある行列（物理ではハミルトニアン）の最小固有値を求める。

仕組み: 変分原理 — 「任意の試行状態の期待値は最小固有値以上」 —

$$\langle \psi(\theta) | H | \psi(\theta) \rangle \geq \lambda_{\min}$$

等号は $|\psi(\theta)\rangle$ が最小固有値の固有状態のとき。PQCで作った試行状態の期待値を**最小化する θ を探せば**最小固有値に近づく。

位置づけ: スライド35の「以降のQSVM・QGAN・QCNNすべてがこの被せ方を踏襲する」が重要。三目並べソルバーの「PQCで処理 → 測定 → 古典で最適化」もVQEと同じ骨格である。

変分原理は線形代数の Rayleigh 商の最小値が最小固有値に等しい、の言い換え。固有値を学んでいれば $\frac{\langle \psi | H | \psi \rangle}{\langle \psi | \psi \rangle}$ の最小化と聞けば腑に落ちる。

QSVM（スライド36, 37）

古典SVM: マージン最大の境界を引く分類器。まっすぐ分けられないデータも高次元へ写す ϕ で平面分離。鍵は**カーネルトリック**: ϕ 自体は不要で内積 $K(x, x') = \langle \phi(x), \phi(x') \rangle$ だけでよい。

量子化: **カーネル K の計算だけ量子で行う**。量子の特徴写像 = Feature Map (§ 4) が古典 ϕ の量子版。最適化は古典SVMを再利用。**Encodingで作る量子特徴空間が古典で計算しにくい内積を与えうる**のが期待される点。

出典（スライドより）: Havlíček et al., “Supervised learning with quantum-enhanced feature spaces”, Nature 567, 209–212 (2019)。

QGAN（スライド38, 39）

古典GAN: Generator と Discriminator をminimaxで競わせ本物そっくりの分布を生成。モード崩壊という失敗もある。

量子化: G/Dの片方または両方を量子回路にする。骨格は古典GANと同じ。**量子化の難所はデータの読み込み**（スライド39）—— § 4のEncoding問題がここでも顔を出す。QMLのあらゆる手法で、古典データを扱う限りEncodingがボトルネックになる、という通底するテーマである。

QCNN（スライド40）

仕組み: 古典CNNの骨格（局所性とパラメータ共有）を量子で実現。畳み込み層 = 局所ユニタリ、プーリング層 = 一部qubitを測定しトレースアウトして次層の入力を減らす。

Barren Plateauとの関係: パラメータがqubit数に対して**対数的にしか増えず**、層を経るごとにqubit数が減るので § 12のBarren Plateauを**構造的に避けやすい**（スライド40）。スライド29で「QCNN > QNN」になったのもこの構造的優位の反映と読める。QCNNの正体と応用は § E3・§ E6 で詳しく扱う。

トレースアウトは、一部のqubitを測定して周辺化し捨てる操作。古典CNNのプーリング（領域を1値に集約）の量子版。

用語

原語	訳語/定着訳	短い定義
VQE	変分量子固有値ソルバー	変分原理で最小固有値を求めるPQCアルゴリズムの原型
変分原理	variational principle	試行状態の期待値が最小固有値以上、という定理
カーネルトリック	kernel trick	内積 K だけで非線形分離する手法
モード崩壊	mode collapse	GANで生成分布が一部につぶれる失敗
トレースアウト	trace out	一部qubitを周辺化して捨て次元を下げる操作

§ 14 考察：量子優位はどこにあるか

対応: スライド31～34, 41, 42

要点

「量子単体が古典に届かなかった」は失敗ではなく**想定内**（スライド31）。三目並べは単純すぎて量子優位の余地が小さい。それでもハイブリッドが古典に並ぶ/上回ることは、量子の部品が何かを足している示唆。

議論の構造

- ・「**性能が出ない**」の意味（スライド31）：三目並べは古典で容易に解け（最善どうしは引き分け）、汎用回路では量子優位の余地が小さい。**問題が単純なほど量子優位の余地は小さい**。

- ・ **伸びしろ**（スライド32）：ノイズ付きシミュレータでも動くか、戦術的要素を組み込めるかを検証。終盤の守りが甘い限界も正直に提示。
- ・ **スケーラビリティ**（スライド33）：規模を大きくすれば優位が出るか? → qubit増でBarren Plateau（§12）、深化で局所最適やノイズ。**規模だけでなく優位の出る条件・構造も重要**で最前線でも未知数。
- ・ **量子インターネットへの応用**（スライド34）：ノイズ通信路を挟んでも性能低下が限定的なら、広域量子アプリでQMLが活躍しうる。
- ・ **これからの方向**（スライド41）：古典データならEncodingが壁なのでハイブリッドが現実的。量子データをQMLで直接処理する道もありうる。FTQC時代には状況が変わる。

行間（講義全体の結論）

スライド42「量子AIは古典AIからかけ離れたものではなかった」が最も重要なメッセージである。§1で「部品の差し替え」として始まり、§13で関連手法がすべて「PQC+古典最適化」の変奏だと見て、ここで回収される。**QMLは魔法ではなく古典MLの延長線上にある工学**である。

同時に講義は量子優位について**慎重な不可知論**を貫く。「量子優位は無条件でなく設計・問題次第で不明なことも多い」（スライド42）。過剰な期待も過剰な悲観もせず、「どんな条件で優位が出るか」を未解決問題として残す誠実な結論である。

読解ヒント

スライド31の図「問題の複雑さ → 量子優位の余地」は右肩上がりの模式図で三目並べを左端に置く。ただし「**複雑なら必ず優位が出る**」とは言っていない。余地があることと実際に優位が取れることは別である。


実装パート：論文の4エンジンを組み立てる

ここからは概念パート（§0～§14）の応用編である。論文 Kamei et al. (2025) が定義する4つのエンジンを、論文ソースの回路図とノートブック（配布版 lec8 / 原案版 nisq3）の実コードで解説する。原理の説明は概念パートに集約済みで、ここでは論文・ノート固有の情報（回路図・コード・命名・実験結果）に絞り、概念は §N の形で逆参照する。

§ E0 全体像：エンジンという単位

対応: 論文 Fig. scheme_of_engines / スライド25 / ノート EX2-3

論文は三目並べを打つAI一式を**エンジン (engine)**と呼ぶ。枠は共通で、中央のNNだけが古典/量子/ハイブリッドに差し替わる (§1)。



図E0: エンジンの共通枠。Current state (盤面) $\rightarrow$ NNs $\rightarrow$ Next state を、Huber Loss $\cdot$ Adam $\cdot$ Weight update の強化学習ループ (§ 9) が回す (Kamei et al. 2025)

損失が **Huber Loss**、最適化が **Adam** という具体的選択が明示されている。ノートの `train_selfplay` (§9) が使う `nn.SmoothL1Loss()` がこの Huber Loss である。論文は全 54 エンジンを比較しており、本副読本は各カテゴリの代表を扱う。


行間

個々のNNは内部構造がバラバラで直接比較できない（§ 10のEloの動機と同じ）。「盤面→次の一手」を返すエンジンとして包めば、中身が何であれ同じ土俵で対戦させられる。**エンジン = 比較可能な単位に揃えるラッパー**である。

§ E1 古典エンジン：CNN / CCNN

対応: 論文 § III-A・Fig. ccnn_engine / 原案ノート CCNN2 / 配布ノート ClassicalAI

論文の古典エンジンは畳み込み (CCNN) + 全結合 (CNN) で、“Stronger” と “Weaker” の2変種がある。



図E1: 古典CCNNエンジン。盤面を数値化し畳み込み層→全結合層で9マスのスコアを出す (Kamei et al. 2025)

ノートとの対応 (重要な差分)

2つのノートと論文で古典AIの中身が違う:

	古典AIの構造	出典
配布ノート lec8	全結合のみ (Linear 9→64→9)	演習用に簡略化
原案ノート nisq3	畳み込み CCNN2 (Conv2d + Linear)	論文の “Weaker” 相当
論文	CCNN (Stronger / Weaker)	比較の基準

原案ノートの CCNN2 はコメントに「論文では “Weaker”」と明記されている:

```
class CCNN2(nn.Module):    # 論文の "Weaker" 版
    def __init__(self):
        self.conv1 = nn.Conv2d(1, 16, kernel_size=3, bias=False) # 3×3盤に畳み込み
        self.linear = nn.Linear(16, 9, bias=True)
    def forward(self, state):
        x = torch.reshape(state, (1,3,3)) # 9次元 → 3×3盤
        x = self.conv1(x) # 畳み込み (盤の局所パターン)
        x = torch.flatten(x)
        return self.tanh(self.linear(x)) # 9スコア
```

配布ノートの全結合 ClassicalAI はこれをさらに単純化した教材版である。

行間

スライド29の「古典」は論文のCCNN（畳み込み）であって配布ノートの全結合ではない。**Elo比較図の「古典」と演習で動かす「古典AI」は厳密には別物**である。畳み込みは盤の構造（縦横斜めの並び）を活かすぶん全結合より強くなりやすいので、演習の古典AIのEloが論文の値と一致しなくても不思議はない。

§ E2 量子単体エンジン：QNN

対応: 論文 § III-B / 原案ノート QNNComponent / 概念は § 4・§ 5・§ 6

QNNエンジンは畳み込み構造を持たない汎用PQCである。embedding (§ 4) + ansatz (§ 5) + 測定 (§ 6) で、論文では9 qubit（盤面9マス）を使う。


構成要素（原案ノート QNNComponent）

embedding は4種、ansatz は2種から選べる。スライド14・15で名前だけ出た **TPE / HEE** の正体がこれである：

```
class QNNComponent:
    def TPE(self, reps=1): # Tensor Product Embedding: 各qubitにRxだけ（もつれなし）
        for i in range(self.n_qubits):
            qc.rx(theta[i], i)
    def HEE(self, reps=1): # Hardware-Efficient Embedding: Rx + CX鎖（軽いもつれ）
        for i in range(self.n_qubits):
            qc.rx(theta[i], i)
        for i in range(self.n_qubits-1):
            qc.cx(i, i+1)
```

- TPE: R_x を載せるだけ。もつれなし。§ 4のAngle encodingそのもの。
- HEE: R_x の後にCX鎖。軽いもつれを入れる。

embedding と ansatz の回路図



図E2: (a) Embedding 4種 (ZFeatureMap, HEE, TPE, ZZFeatureMap) と (b) Ansatz 3種 (RealAmplitudes, EfficientSU2, QCNN) の回路図 (Kamei et al. 2025 付録)

本副読本で最も情報量の高い1枚である。読み方:

- (a) ZFeatureMap: 各qubitに $H + P$ (位相、角度 $2x_i$)。もつれなし。
- (a) HEE: $R_x(\theta_i) + CX$ 。隣接qubitをもつれさせる。
- (a) TPE: $R_x(\theta_i)$ のみ。最も単純。
- (a) ZZFeatureMap: $H +$ 単独位相に加え、qubit対への $2(\pi - x_i)(\pi - x_j)$ 位相 ($x_i x_j$ の積)。§4で述べた「積が入るから非線形」がこの位相に現れている。
- (b) RealAmplitudes: $R_y + CX$ (§5の標準ansatz)。
- (b) EfficientSU2: $R_y, R_z + CX$ (§5で「 θ が倍」と述べた理由がここ)。
- (b) QCNN: conv (畳み込み) と pool (プーリング) のラベル付きゲート (§E3)。


行間

QNN単体エンジンはハイブリッド (§E4) と違って古典の圧縮層がない。盤面9次元を直接9 qubitに載せる。「純粋に量子だけでどこまでできるか」を見る構成で、後で見るように古典に届かない。§4で論じた「Encodingのロス」「読み出しのロス」が古典層の助けなしに直接効くためと論文は分析する。

§ E3 量子畳み込みエンジン：QCNN

対応: 論文 § III-B · Fig. qcnnc_engine / 概念は § 13 · § 12 配布 · 原案ノートには実装がなく、論文ソースが唯一の一次資料。

QCNNエンジンはansatzを畳み込み+プーリング構造にした量子エンジンである。論文では18 qubitを使い、9マスを複製して18量子ビットに載せる。



図E3: QCNNエンジン。盤面を9次元に数値化し18qubitに複製して載せ、QCNN層を通して9マス（A～I）のスコアにマップ（Kamei et al. 2025）

QCNN ansatz の構造

§ E2の回路図 (b) 右下“QCNN”の conv/pool ラベルが、§ 13で概念的に説明したQCNNの実体である：

- **conv層**: 隣接qubit対に2qubitユニタリ (R_y, R_z の組)。古典CNNの畳み込みフィルタに対応し局所相関を拾う。
- **pool層**: 一部qubitに制御回転をかけて縮約。古典CNNのプーリング（§ 13のトレースアウト）に対応。

行間：なぜ18 qubitか


QNN単体が9 qubit（盤面そのまま）なのにQCNNは18 qubit（9マスを複製）。QCNNはpool層でqubitを段階的に減らすので、入力9のままでは縮約後に9マス出力ぶんの情報が残らない。入力を18に水増しし、conv/poolで減らしても最終的に9マス出力を確保する設計である。

§ 13で「QCNNはqubitが減るのでBarren Plateau（§ 12）を構造的に避けやすい」と述べた。これがQCNNエンジンの設計上の狙いの一つだが、三目並べという小問題では構造的利点が古典を上回る強さには結びついていない（§ E5）。

§ E4 ハイブリッドエンジン：HNN

対応: 論文 § III-C・Fig. cqcnn_engine / 配布ノート HybridAI / 原案ノート CNN_QNN_CNN_* / 概念は § 8

ハイブリッド（論文の呼称 **HNN** = Hybrid Neural Network）は、古典CNNで入出力を挟み、隠れ層を量子（QNN または QCNN）にする。§ 8の「サンドイッチ」構造そのものである。



図E4: HNNエンジン。盤面→入力CNN層→量子層（QNN or QCNN）→出力CNN層→9マス（Kamei et al. 2025）

ノートとの対応

配布ノートの `HybridAI` (§ 8) と原案ノートの `CNN_QNN_CNN_sampler / _estimator` がHNNの実装である。クラス名 “`CNN_QNN_CNN`” は「古典CNN → 量子QNN → 古典CNN」のサンドイッチ順を表す命名で、この “`CNN`” は古典の畳み込みであり量子CNN (QCNN) ではない。

```
class CNN_QNN_CNN_sampler: # Sampler版: 量子層出力  $2^n$  次元 (§ 6)
    self.cqnn = nn.Sequential(
        nn.Linear(9, n_qubits), # 古典: 圧縮
        ScratchTorchConnector(qnn=...), # 量子層
        nn.Linear(2**n_qubits, 9)) # 古典:  $2^n \rightarrow 9$  (後段が大きい)

class CNN_QNN_CNN_estimator: # Estimator版: 量子層出力  $n$  次元 (§ 6)
    self.cqnn = nn.Sequential(
        nn.Linear(9, n_qubits),
        ScratchTorchConnector(qnn=...),
        nn.Linear(n_qubits, 9)) # 古典:  $n \rightarrow 9$  (後段が小さい)
```

§ 6・§ 8で述べた「読み出し方で後段Linearの入力次元が変わる (2^n vs n)」が、`nn.Linear(2**n_qubits, 9)` と `nn.Linear(n_qubits, 9)` の違いとして現れている。


行間

HNNは隠れ層に QNN を選ぶか QCNN を選ぶかで2系統に分かれる。後の実験で最強だったのは QNN を隠れ層に持つHNN (QCNNではない) であった。§ E3で見たQCNNの構造的利点は三目並べの規模では決定打にならず、汎用QNN + 大きな古典後段 (Sampler版) の方が強かった。「構造の工夫が常に勝つわけではない」設計の難しさを示す例である。

§ E5 実験結果：Eloで7エンジンを比べる

対応: 論文 § IV-B • Fig. rating, Table / スライド29 / ノートEX4

論文は代表7エンジンをラウンドロビン対戦させ、100ゲームごとにEloを更新した。



図E5: 代表エンジンのElo推移。上位5 (古典含む) と量子層のみの2 (QNN・QCNN) に二分される (Kamei et al. 2025)

順位と傾向

最終Elo (論文 Table、代表値) :

エンジン	最終Elo（代表）
Sampler 16 qubit（HNN, TPE+RealAmplitudes）	約1624
Sampler 8 qubit（HNN）	約1599
Estimator 16 qubit（HNN）	約1579
Estimator 8 qubit（HNN）	約1555
古典CNN（Stronger）	約1546
QCNN単体（18 qubit, HEE+QCNN）	約1468
QNN単体（9 qubit, TPE+EfficientSU2）	約1456

定性的傾向は3つ:

1. **エンジンは2グループに割れる**。古典含む上位5（4つのHNN + 古典）と、量子層のみの下位2（QCNN単体・QNN単体）。上位は安定してEloを伸ばし、下位は初期値1500付近で停滞する。論文は「停滞 = 引き分けが多い（勝ち切れない）」と分析。
2. **qubit数を増やすとEloが上がる**（この設定では）。16 qubit版が8 qubit版を上回る。
3. **Estimator版（少パラメータ）も古典を上回る**。Sampler版が最強なのは後段Linearが大きい（パラメータ多）ことが効くが、パラメータの少ないEstimator版でも古典を超えた。「パラメータ数だけが強さの決定要因ではない」（§ 6・§ 8で予告した観察の裏付け）。

スライド29との対応と留保

スライド29の「ハイブリッド > 古典 > QCNN > QNN」は実データと整合する（HNN群 > 古典 > QCNN単体 > QNN単体）。ただし実図はもっとニュアンスがあり、上位5つは互いに接近し終盤で順位が入れ替わる。**Eloのゆらぎは20～30点**で、70点未満の差は有意でない。「HNN群と古典の差」は明確だが「HNN群内の細かい順位」はゆらぎを含む。

行間（§ 14への接続）

最も重要な解釈は、**量子層のみのエンジン（QNN・QCNN単体）が古典に届かなかった点**である。論文はこれを失敗ではなく「盤面情報の入力（Encoding）と出力の処理に改善余地がある」「三目並べに特化した回路を作れば改善しうる」と分析する。§ 14の「Encodingが壁」「汎用回路では優位が出にくい」が実データの解釈として現れている。

QCNN単体がQNN単体をわずかに上回る（1468 vs 1456）のは§ 13のQCNNの構造的利点の反映と読めるが、差12点はゆらぎ（20～30点）の範囲内である。「**QCNN > QNN**」をこのデータから断定するのは慎重であるべきで、論文も決定的主張はしていない。

§ E6 QCNNは三目並べ以外で何に使えるか

対応: § 13・§ E3 の応用編。出典は本文中に明示。三目並べはQCNNの「練習問題」にすぎない。QCNNが本来どんな問題に向くかを構造から逆算する。

§ E3でQCNNの回路 (conv + pool) を見た。ここでは「この構造は三目並べ以外の何に役立つのか」を扱う。

QCNNの構造的性質（なぜ特定の問題に向くか）

QCNN原論文 — Cong, Choi, Lukin (2019) “Quantum Convolutional Neural Networks”, Nature Physics 15, 1273–1278 (arXiv:1810.03787) — が挙げる特徴は3つ:

1. **パラメータが $O(\log N)$:** N qubit入力に対し学習パラメータは $\log N$ オーダー。pool層で qubitを半分ずつ畳むので層の深さが $\log N$ で済む。§ 12のBarren Plateauを**構造的に緩和**する。
2. **局所性 (locality):** conv層は隣接qubitだけにユニタリをかける。古典CNNが隣接ピクセルを畳み込むのと同じ。**空間的・局所的な相関を持つデータ**に向く。
3. **繰り込み (renormalization):** pool層で段階的に粗視化する構造は物理の繰り込み群（細部を捨て大域的特徴を残す）と対応。QCNNはMERA（多スケールエンタングルメント繰り込みansatz）という物理構造を組み込んでいる。**大域的性質が細部によらず決まる問題**に向く。

この3点から、QCNNが向くのは「**局所的な相互作用から大域的な分類ラベルが決まる**」問題だと読める。

向いている問題①：量子相認識（原論文の主題）

原論文の第一の例は**量子相認識 (quantum phase recognition)**。1次元の対称性保護トポロジカル相 (SPT phase) に属する量子状態を識別する。

- ・ **入力:** 量子多体系の基底状態（量子状態そのもの。古典データではない）。
- ・ **出力:** その状態がどの「相」に属するか（物質の相の量子版）。
- ・ **なぜ向くか:** 相は局所相互作用から決まる大域的性質で、繰り込みの構造と合う。原論文は、厳密に解ける少数点で訓練したQCNNがパラメータ領域全体の相図を再現できることを数値的に示した。

これは§ 1の4象限の「**量子データ × 量子アルゴリズム**」である。入力が最初から量子状態なので§ 4の「Encodingのロス」が生じない。これがQCNN本来の土俵であり、三目並べ（古典データ）とは象限が違う。

向いている問題②：量子誤り訂正符号の最適化（原論文の第二の例）

原論文の第二の例は、与えられた誤りモデルに対し最適なQEC符号を設計すること。QCNNのpool構造がQECの「シンドローム測定で誤りを検出し論理情報だけ残す」操作と自然に対応する。情報工学の符号理論とも接点がある。

向いている問題③：古典データの分類（最も平易な練習問題）

QCNNを古典データの2クラス分類に使うこともできる。本来の土俵ではないが、三目並べと同じく練習問題として平易である。Qiskit Machine Learning 公式チュートリアル“The Quantum Convolution Neural Network”が、**画像が横線か縦線かを判定する2クラス分類**を扱う：

- **入力**: 小さな画像（各ピクセルを1 qubitに。例えば 8 qubit）。
- **処理**: ZFeatureMapでEncoding → conv層とpool層を3回繰り返して 8 qubit → 1 qubit に畳む。
- **出力**: 最後の1 qubitを測定。横線か縦線かを判定。
- **最適化**: COBYLA（古典の最適化手法）。

「pool層でqubitを半分ずつ減らし最後の1 qubitの測定で2クラスを判定」という流れは、§ E3の三目並べQCNN（18 qubit → 縮約 → 9マス出力）と同じ構造である。**出力が2クラス（1 qubit）か9マス（複数出力）かが違うだけ。**

実装の「形」（最も平易なスケッチ）

以下は「形」を示す骨格であり、動作する完全なコードではない。実際に動かすにはチュートリアル本体を参照。

```
# 1. Encoding: 画像をqubitに載せる (§ 4)
feature_map = z_feature_map(num_qubits=8)

# 2. QCNN ansatz: conv層とpool層を交互に (§ E3)
ansatz = QuantumCircuit(8)
ansatz.compose(conv_layer(8, ...), inplace=True)      # 8 qubit
ansatz.compose(pool_layer([0,1,2,3],[4,5,6,7], ...), True) # → 4 qubit
ansatz.compose(conv_layer(4, ...), inplace=True)      # 4 qubit
ansatz.compose(pool_layer([0,1],[2,3], ...), inplace=True) # → 2 qubit
# ... 最後は1 qubitまで畳む

# 3. 読み出し (§ 6) : 残った1 qubitのZ期待値
observable = SparsePauliOp("Z" + "I"*7)

# 4. QNN化して古典最適化 (§ 7・§ 8)
qnn = EstimatorQNN(circuit=..., observables=observable, ...)
classifier = NeuralNetworkClassifier(qnn, optimizer=COBYLA())
classifier.fit(X_train, y_train) # 横線/縦線を学習
```

§ E3の三目並べQCNNと見比べると、**Encoding (§ 4) → conv/pool ansatz (§ E3) → 測定 (§ 6) → 古典最適化 (§ 7)** という流れが完全に共通している。問題が三目並べでも横線/縦線判定でも組み立て方は同じ —— § 1「枠は共通、中身を差し替え」のQCNNにおける現れである。

出典: 実装構造は Qiskit Machine Learning 公式チュートリアル “The Quantum Convolution Neural Network” (qiskit-community.github.io/qiskit-machine-learning) に基づく。完全な動作コードはチュートリアル本体を参照。

行間：三目並べQCNNが振るわなかった理由の再解釈

§ E5で三目並べのQCNN単体が古典に届かなかった (Elo約1468)。QCNN本来の土俵 (量子相認識のような量子データ・局所性・繰り込みが効く問題) と照らすと理由が見える。三目並べの盤面は古典データで、9マスの局所性も画像ほど強くない (縦横斜めの勝ち筋は大域的関係)。**QCNNの構造的強み (局所性・繰り込み) が活きにくい問題に当てはめた格好である**。三目並べでの結果はQCNNの弱さではなく「適材適所でなかった」と読むのが公平である。

用語

原語	訳語/定着訳	短い定義
quantum phase recognition	量子相認識	量子状態がどの物理相に属するかを識別するタスク
SPT phase	対称性保護トポロジカル相	対称性に守られたトポロジカルな量子相
MERA	多スケールエンタングルメント繰り込みansatz	繰り込みの構造を持つテンソルネットワーク
renormalization	繰り込み	細部を粗視化し大域的特徴を残す操作

関連して読むとよい論文

- QCNN原典: Cong, Choi, Lukin (2019) “Quantum Convolutional Neural Networks”, Nature Physics 15, 1273–1278 (arXiv:1810.03787)。 $O(\log N)$ パラメータ、量子相認識とQEC符号最適化の2例。
- QCNNがBarren Plateauを持たないことの理論解析として Pesah et al. (2021) “Absence of Barren Plateaus in Quantum Convolutional Neural Networks” (Phys. Rev. X 11, 041011, arXiv:2011.02966) がある。書誌の細部に一部不確かさが残るため “absence of barren plateaus quantum convolutional” で検索して確認することを推奨する。

全体のまとめ

論証構造

claim (QMLは古典部品の差し替え, § 1) → method (三目並べソルバーを古典/量子/ハイブリッドで実装し枠を共通化, § 2–§ 8・§ E0–§ E4) → evaluation (Eloで定量比較, § 9–§ 10・§ E5) → result (HNN群 > 古典 > QCNN単体 > QNN単体, § E5) → interpretation (量子単体の劣勢は想定内、ハイブリッドの上積みは量子の寄与を示唆, § 14) → caveat (規模・パラメータ依存で決定的でない, § 10・§ E5・§ 14)。

重要な3点

1. 「**枠は共通、AIだけ差し替え**」 (§ 1) が全体の背骨。強化学習の枠 (§ 9) がこれを可能にし、Elo (§ 10) が同じ土俵での比較を可能にする。
2. 逆伝播は量子層内部で使えないが、**Parameter shift** (§ 7) が局所勾配を供給し、**TorchConnector**で古典autogradに接続すれば学習全体は地続き (§ 3・§ 7・§ 8)。これが技術的な要。
3. **Barren Plateau** (§ 12) が「大きくすれば強くなる」を阻む量子固有の壁。ハイブリッドで量子層を小さく保つ (§ 8)、QCNNで構造的に避ける (§ 13・§ E6)、が現実的対処。

限界・批判されうる点

- Eloによる比較は同一条件下の相対評価で、qubit数・パラメータ数を変えると順位が動きうる (手法の優劣の証明ではない)。講義自身が繰り返し留保している。
- 三目並べという単純問題での結果が複雑問題に外挿できる保証はない。「複雑なら優位の余地がある」は余地の話で実現の話ではない。
- 「量子層が何かを足している」は間接的示唆 (パラメータ数だけでは説明しにくい) であって量子優位の直接証明ではない。

関連して読むとよい論文

- 元論文: Kamei et al. (2025), arXiv:2503.21514。
- Parameter shift: Mitarai et al. (2018) arXiv:1803.00745 / Schuld et al. (2019) arXiv:1811.11184。
- Barren Plateau: McClean et al. (2018) arXiv:1803.11173。
- QSVM: Havlíček et al. (2019) Nature 567, 209–212。
- QCNN: Cong, Choi, Lukin (2019) Nature Physics 15, 1273–1278 (arXiv:1810.03787)。

(著者・年・タイトルに確信のあるもののみ記載。書誌の細部に確信がないものは本文中で検索を推奨する形に留めた。)

読者プロフィール更新提案

このセッションで観察された手がかりに基づく提案。 `reader_profile.md` への反映はユーザー操作で行うこと（Claudeはナレッジを直接書き換えない）。

- ・読者ゾーンは「学部後半（B3）・量子は専門外の情報工学科」。量子回路は読め、ゲートは既習だが復習を要する、という自己申告。QMLは初出。
- ・観察された理解度: 量子回路・ゲートの基本は前提として進められた。機械学習の基礎（NN・勾配・逆伝播）も既習想定で問題なかった。強化学習・期待値・パウリ代数は補足を要する領域。
- ・既知の概念（分野固有）に「量子ゲート（X,H,Rx/Ry/Rz,CX）」「ニューラルネット・勾配降下・逆伝播の基礎」を追加候補。
- ・既読の関連論文に「Kamei et al. 2025 (arXiv:2503.21514) QMLによる三目並べ」を追加候補。
- ・苦手・要復習に「強化学習（Q学習・Bellman）」「ランダム行列・ユニタリデザイン（Barren Plateauの証明）」を追加候補。
- ・スタイル選好: 数理的背景は「厚め」を希望（Parameter shift導出、Barren Plateau分散議論まで）。テーマ別再編 + 実装パート併設の構成を採用。

本副読本は個人学習用資料である。論文 Kamei et al. (2025) および Cong et al. (2019) 等から引用した図は学習補助目的（フェアユース）であり、著作権は各原著者に帰属する。再配布・公開はしないこと。